```
from IPython.core.display import display, HTML
display(HTML("<style>.container { width:95% !important; }</style>"))

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import pandas_datareader as web
import datetime as dt
from scipy.optimize import minimize
import sys
```

Set configuration to run code

Haz doble clic (o ingresa) para editar

```
flag_runlocal  = False    # "False" para ejecutar en google colab
flag_useserver = True    # "False" para ejecutar con conexión a internet via proxy


if flag_runlocal:
    # ---> Ejecución local
    pathBayesInfer = ''
    if flag_useserver:
        from ConfigProxy import proxy
        # Set the proxy with authentication
        import os
        os.environ['http_proxy'] = proxy
        os.environ['https_proxy'] = proxy

else:
    # ---> Desde github-to-colab
    !git clone https://github.com/Alledar/BayesInfer.git
    pathBayesInfer = '/content/BayesInfer/'

sys.path.append(pathBayesInfer+'02_Libraries')
import DSGEstuff as DG
import KFstuff as KF
from GeneralComplements import HP
```

```
Cloning into 'BayesInfer'...
remote: Enumerating objects: 202, done.
remote: Counting objects: 100% (11/11), done.
remote: Compressing objects: 100% (2/2), done.
remote: Total 202 (delta 10), reused 9 (delta 9), pack-reused 191 (from 1)
Receiving objects: 100% (202/202), 6.03 MiB | 7.35 MiB/s, done.
Resolving deltas: 100% (100/100), done.
```

Estimación de modelos de equilibrio general dinámico estocástico

Revisaremos los pasos de la estimación de manera secuencial

El modelo: RBC simple

El modelo tal como es derivado

El modelo incluye un conjunto de ecuaciones de equilibrio parcial

1. The Euler equation: $\frac{1}{\exp(u_t)}\frac{1}{C_t} = \beta E_t\left[\frac{1}{C_{t+1}}\left(R_{t+1} + \frac{1-\delta}{\exp(u_{t+1})}\right)\right]$
2. Oferta de trabajo: $\phi H_t^{\eta} = W_t C_t^{-1}$
3. Restricciones tecnológicas de producción: $Y_t = \exp(z_t) K_{t-1}^{\alpha} H_t^{1-\alpha}$
4. Demanda de trabajo: $W_t = (1-\alpha)\frac{Y_t}{H_t}$
5. Demanda de capital: $R_t = \alpha\frac{Y_t}{K_{t-1}}$
6. Acumulación de capital: $K_t = (1-\delta)K_{t-1} + \exp(u_t)I_t$
7. Condición de limpieza de mercados: $Y_t = C_t + I_t$
8. Choque de productividad: $z_t = \rho_z z_{t-1} + \sigma_z \varepsilon_t^z$
9. Choque a la eficiencia de la inversión: $u_t = \rho_u u_{t-1} + \sigma_u \varepsilon_t^u$

Categorización de variables

Adaptamos la notación de Schmitt-Grohé y Uribe (2004). En este paper, las variables del modelo se categorizan como se presenta a continuación

1. Variables endógenas: $\mathbf{Y}_t = [Y_t,\ C_t,\ I_t,\ H_t,\ W_t,\ R_t]'$
2. Variables de estado endógenos y/o rezagos: $\mathbf{X}_{1,t} = [K_{t-1}]$
3. Variables de estado exógenos: $\mathbf{X}_{2,t} = [z_t,\ u_t]'$
4. Variables de estado: $\mathbf{X}_t = [\mathbf{X}_{1t}',\ \mathbf{X}_{2t}]'$
5. Choques estructurales: : $\boldsymbol{\varepsilon}_t = [\varepsilon_t^z,\ \varepsilon_t^u]'$

El sistema de expectativas racionales

En línea con Schmitt-Grohé y Uribe (2004), el DSGE no lineal se puede escribir como:

$$\mathrm{E}_t \mathbf{f}(\mathbf{Y}_{t+1}, \mathbf{Y}_t, \mathbf{X}_{t+1}, \mathbf{X}_t) = 0$$

donde

$$\mathbf{X}_{2,t+1} = \Lambda \mathbf{X}_{2,t} + \tilde{\boldsymbol{\eta}} \boldsymbol{\varepsilon}_{t+1}$$

La solución (por perturbación) a este sistema tiene la forma

$$\mathbf{Y}_t = \mathbf{g}(\mathbf{X}_t, \boldsymbol{\sigma})$$
$$\mathbf{X}_{t+1} = \mathbf{h}(\mathbf{X}_t, \boldsymbol{\sigma}) + \boldsymbol{\sigma\eta\varepsilon}_{t+1} \text{ con } \boldsymbol{\eta} = [\mathbf{0},\ \tilde{\boldsymbol{\eta}}']'$$

El estado estacionario

El punto fijo del sistema se calcua resolviendo $\mathbf{Y}_{ss}$ y $\mathbf{X}_{ss}$ a partir de $\mathrm{E}_t \mathbf{f}(\mathbf{Y}_{ss}, \mathbf{Y}_{ss}, \mathbf{X}_{ss}, \mathbf{X}_{ss}) = 0$

1. Tasa de interés real: $R_{ss} = \frac{1-\beta(1-\delta)}{\beta}$
2. Salario real: $W_{ss} = (1-\alpha)\left[\frac{1-\beta(1-\delta)}{\beta\alpha}\right]^{-\frac{\alpha}{1-\alpha}}$
3. Acevo de capital físico: $K_{ss} = \left[\frac{(1-\alpha)\beta\alpha}{\phi(1-\beta(1-\delta+\alpha\delta))}\right]^{\frac{1}{1+\eta}}\left[\frac{1-\beta(1-\delta)}{\beta\alpha}\right]^{-\frac{\alpha+\eta}{(1+\eta)(1-\alpha)}}$
4. Producción: $Y_{ss} = \frac{1-\beta(1-\delta)}{\beta\alpha} K_{ss}$
5. Inversión: $I_{ss} = \delta K_{ss}$
6. Consumo: $C_{ss} = \frac{1-\beta(1-\delta+\alpha\delta)}{\beta\alpha} K_{ss}$
7. Trabajo: $H_{ss} = \left[\frac{1-\beta(1-\delta)}{\beta\alpha}\right]^{\frac{1}{1-\alpha}} K_{ss}$
8. Choque de productividad: $Z_{ss} = 1$
9. Choque de efectividad de la inversión: $U_{ss} = 1$

El sistema log-linearizado

Considere la siguiente transformación para una variable cualquiera M_t: $M_t = M_{ss}\exp(m_t)$ entonces m_t es el desvío porcentual de M_t respecto de su estado estacionario M_{ss}. Esto debido a que $m_t = \log \frac{M_t}{M_{ss}}$.

Así, si reemplazamos a todas las variables (sea esta M_t) por su equivalente en desvíos (esto es, $M_{ss}\exp(m_t)$) en el sistema no lineal de arriba. Así, luego de calcular la aproximación e Taylor de primer orden para cada ecuación se genera el siguiente sistema lineal:

1. Ecuación de Euler: $c_t = E_t c_{t+1} - [1-\beta(1-\delta)] E_t r_{t+1} + [\beta(1-\delta)\rho_\mu - 1] u_t$
2. Oferta de trabajo: $\eta h_t = w_t - c_t$
3. Restricciones tecnológicas de producción: $y_t = z_t + \alpha k_{t-1} + (1-\alpha) h_t$
4. Demanda de trabajo: $w_t = y_t - h_t$
5. Demanda de capital: $r_t = y_t - k_{t-1}$
6. Acumulación de capital: $k_t = (1-\delta) k_{t-1} + \delta i_t + \delta u_t$
7. Condición de limpieza de mercados: $y_t = \frac{1-\beta(1-\delta+\alpha\delta)}{1-\beta(1-\delta)} c_t + \frac{\delta\beta\alpha}{1-\beta(1-\delta)} i_t$
8. Choque de productividad: $z_t = \rho_z z_{t-1} + \sigma_z \varepsilon_t^z$
9. Choque a la eficiencia de la inversión: $u_t = \rho_\mu u_{t-1} + \sigma_u \varepsilon_t^u$

Por lo tanto, las variables quedan categorizadas de la siguiente manera

1. Variables endógenas: $\mathbf{y}_t = [y_t,\ c_t,\ i_t,\ h_t,\ w_t,\ r_t]'$
2. Variables de estado endógenos y/o rezagos: $\mathbf{x}_{1,t} = [k_{t-1}]$
3. Variables de estado exógenos: $\mathbf{x}_{2,t} = [z_t,\ u_t]'$
4. Variables de estado: $\mathbf{x}_t = [k_{t-1},\ z_t,\ u_t]'$

5. Choques estructurales: : $\boldsymbol{\varepsilon}_t = [\varepsilon_t^z, \ \varepsilon_t^u]'$

El sistema lineal de expectativas racionales (SLER)

Regresamos a la notación de Schmitt-Grohé y Uribe (2004). Así, definamos $\mathbf{f}_{y'} = \frac{\partial \mathbf{f}(\mathbf{Y}_{t+1}, \mathbf{Y}_t, \mathbf{X}_{t+1}, \mathbf{X}_t)}{\partial \mathbf{y}_{t+1}}\Big|_{ss}$, $\mathbf{f}_y = \frac{\partial \mathbf{f}(\mathbf{Y}_{t+1}, \mathbf{Y}_t, \mathbf{X}_{t+1}, \mathbf{X}_t)}{\partial \mathbf{y}_t}\Big|_{ss}$, $\mathbf{f}_{x'} = \frac{\partial \mathbf{f}(\mathbf{Y}_{t+1}, \mathbf{Y}_t, \mathbf{X}_{t+1}, \mathbf{X}_t)}{\partial \mathbf{x}_{t+1}}\Big|_{ss}$ y $\mathbf{f}_x = \frac{\partial \mathbf{f}(\mathbf{Y}_{t+1}, \mathbf{Y}_t, \mathbf{X}_{t+1}, \mathbf{X}_t)}{\partial \mathbf{x}_t}\Big|_{ss}$. Así, el modelo linearizado se puede escribir como:

$$\mathrm{E}_t\left[\mathbf{f}_{y'}\mathbf{y}_{t+1} + \mathbf{f}_y\mathbf{y}_t + \mathbf{f}_{x'}\mathbf{x}_{t+1} + \mathbf{f}_x\mathbf{x}_t\right] = 0$$

donde

$$\mathbf{x}_{2,t+1} = \Lambda \mathbf{x}_{2,t} + \tilde{\boldsymbol{\eta}}\boldsymbol{\varepsilon}_{t+1}$$

Solución

$$\mathbf{y}_t = \mathbf{g}_x \mathbf{x}_t$$
$$\mathbf{x}_{t+1} = \mathbf{h}_x \mathbf{x}_t + \boldsymbol{\eta}\boldsymbol{\varepsilon}_{t+1}$$

- Identificando $\mathbf{f}_{y'}$, $\mathbf{f}_y$, $\mathbf{f}_{x'}$, $\mathbf{f}_x$ a partir de la versión loglinear del modelo $$\mathbf{f}_{y'}=\begin{bmatrix} 0 & 1 & 0 & 0 & 0 & -(1-\beta(1-\delta))\

```
0 & 0 & 0 & 0 & 0 & 0 \\
0 & 0 & 0 & 0 & 0 & 0 \\
0 & 0 & 0 & 0 & 0 & 0 \\
0 & 0 & 0 & 0 & 0 & 0 \\
0 & 0 & 0 & 0 & 0 & 0 \\
0 & 0 & 0 & 0 & 0 & 0 \\
0 & 0 & 0 & 0 & 0 & 0 \\
0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix},$$
```

$\mathbf{f}_y =$

$\Big[0 \quad -1 \quad 0 \quad 0 \quad 0 \quad 0\,0 \quad -1 \quad 0 \quad -\eta \quad 1 \quad 0-1 \quad 0 \quad 0 \quad (1-\alpha) \quad 0 \quad 01 \quad 0 \quad 0 \quad -1 \quad -1 \quad 01 \quad 0 \quad 0 \quad 0 \quad 0 \quad -10 \quad 0$

$$\mathbf{f}*{x'}=*

$\Big[0 \quad 0 \quad 00 \quad 0 \quad 00 \quad 0 \quad 00 \quad 0 \quad 00 \quad 0 \quad 0-1 \quad 0 \quad 00 \quad 0 \quad 00 \quad -1 \quad 00 \quad 0 \quad -1\Big]$

,

\mathbf{f}{x} =

$\Big[0 \quad 0 \quad \beta(1-\delta)\rho_\mu - 10 \quad 0 \quad 0\alpha \quad 1 \quad 00 \quad 0 \quad 0-1 \quad 0 \quad 01-\delta \quad 0 \quad \delta 0 \quad 0 \quad 00 \quad \rho_z \quad 00 \quad 0 \quad \rho_u\Big]$

$$

```
# Calibración inicial
ALPHA_0    = 0.33
BETA_0     = 0.99
DELTA_0    = 0.025
ETA_0      = 0.5
RHOz_0     = 0.95
RHOu_0     = 0.95
SIGMAz_0   = 0.1
SIGMAu_0   = 0.1

param_0 = np.array([[ALPHA_0],[BETA_0],[DELTA_0],[ETA_0],[RHOz_0],[RHOu_0],[SIGMAz_0],[SIGMAu_0]])
```

```
param_0
```

```
array([[0.33 ],
       [0.99 ],
       [0.025],
       [0.5  ],
       [0.95 ],
       [0.95 ],
       [0.1  ],
       [0.1  ]])
```

Haz doble clic (o ingresa) para editar

```
def RBCveranoBCRP(param):
    # Unpack parameters
    ALPHA   = param[0].item()
    BETA    = param[1].item()
    DELTA   = param[2].item()
```

```
    ETA     = param[3].item()
    RHOz    = param[4].item()
    RHOu    = param[5].item()
    SIGMAz  = param[6].item()
    SIGMAu  = param[7].item()
    # fyp
    fyp = np.zeros(shape=(9,6))
    fyp[0,1] = 1
    fyp[0,5] = -(1-BETA*(1-DELTA))
    # fy
    fy = np.zeros(shape=(9,6))
    fy[0,1] = -1
    fy[1,1] = -1
    fy[1,3] = -ETA
    fy[1,4] =  1
    fy[2,0] = -1
    fy[2,3] = 1-ALPHA
    fy[3,0] = 1
    fy[3,3] = -1
    fy[3,4] = -1
    fy[4,0] = 1
    fy[4,5] = -1
    fy[5,2] = DELTA
    fy[6,0] = -1
    fy[6,1] = (1-BETA*(1-DELTA+ALPHA*DELTA))/(1-BETA*(1-DELTA))
    fy[6,2] = (DELTA*BETA*ALPHA)/(1-BETA*(1-DELTA))
    # fxp
    fxp = np.zeros(shape=(9,3))
    fxp[5,0] = -1
    fxp[7,1] = -1
    fxp[8,2] = -1
    # fx
    fx = np.zeros(shape=(9,3))
    fx[0,2] = BETA*(1-DELTA)*RHOu-1
    fx[2,0] = ALPHA
    fx[2,1] = 1
    fx[4,0] = -1
    fx[5,0] = 1-DELTA
    fx[5,2] = DELTA
    fx[7,1] = RHOz
    fx[8,2] = RHOu
    # Lambda
    Lambda = np.zeros(shape=(2,2))
    Lambda[0,0] = RHOz
    Lambda[1,1] = RHOu
    # Eta
    Eta = np.zeros(shape=(3,2))
    Eta[1,0] = SIGMAz
    Eta[2,1] = SIGMAu
    return {'fyp':fyp,'fy':fy,'fxp':fxp,'fx':fx,'Lambda':Lambda,'Eta':Eta} ### me resgresa un diccionario
```

```
# En la calibración inicial
modelo = dict()
modelo['SLER'] = RBCveranoBCRP(param_0) #dar inputs necesarios
```

Solución del SLER (sistema linealizado de expectativas racionales)

Reemplazando la solución (desconocida) en SLER se tiene

$$\mathrm{E}_t\left[\mathbf{f}_{y'}\mathbf{g}_x(\mathbf{h}_x\mathbf{x}_t+\boldsymbol{\eta}\boldsymbol{\varepsilon}_{t+1})+\mathbf{f}_y\mathbf{g}_x\mathbf{x}_t+\mathbf{f}_{x'}(\mathbf{h}_x\mathbf{x}_t+\boldsymbol{\eta}\boldsymbol{\varepsilon}_{t+1})+\mathbf{f}_x\mathbf{x}_t\right]=0$$

Reduciendo y haciendo uso de $\mathrm{E}_t\boldsymbol{\varepsilon}_{t+1}=\mathbf{0}$

$$[\mathbf{f}_{y'}\mathbf{g}_x\mathbf{h}_x+\mathbf{f}_y\mathbf{g}_x+\mathbf{f}_{x'}\mathbf{h}_x+\mathbf{f}_x]\mathbf{x}_t=0$$

Por lo tanto

$$\mathbf{f}_{y'}\mathbf{g}_x\mathbf{h}_x+\mathbf{f}_y\mathbf{g}_x+\mathbf{f}_{x'}\mathbf{h}_x+\mathbf{f}_x=0$$

- Ecuación matricial cuadrática: Sea $\mathbf{A}=\begin{bmatrix}0 & \mathbf{g}_x\\ 0 & \mathbf{h}_x\end{bmatrix}$ entonces $\mathbf{A}^2=\begin{bmatrix}0 & \mathbf{g}_x\\ 0 & \mathbf{h}_x\end{bmatrix}\begin{bmatrix}0 & \mathbf{g}_x\\ 0 & \mathbf{h}_x\end{bmatrix}=\begin{bmatrix}0 & \mathbf{g}_x\mathbf{h}_x\\ 0 & \mathbf{h}_x^2\end{bmatrix}$

Así, la ecuación de arriba se puede reescribir como

$$\begin{bmatrix}\mathbf{f}_{y'} & 0\end{bmatrix}\mathbf{A}^2+\begin{bmatrix}\mathbf{f}_y & \mathbf{f}_{x'}\end{bmatrix}\mathbf{A}+\mathbf{f}_x=0$$

Este problema lo resolvemos numéricamente por la rutina `SolveDSGE` del paquete `DSGEstuff.py`. Esta función utiliza una versión de la descomposición `qz` propuesto por Chris Sims.

```
modelo = DG.SolveDSGE(modelo) #resolvera el modelo dando los input necesarios
```

```
modelo['solución']['gx'] ## guarda gx y hx
```

```
array([[ 0.16282831,  1.47091617,  0.47091617],
       [ 0.53709329,  0.41662624, -0.58337376],
       [-1.05527989,  4.90227976,  3.90227976],
       [-0.24950998,  0.70285995,  0.70285995],
       [ 0.41233829,  0.76805621, -0.23194379],
       [-0.83717169,  1.47091617,  0.47091617]])
```

Para comparar con dynare

$$\begin{aligned} \mathbf{x}_{t+1} &= \mathbf{h}_x \mathbf{x}_t + \boldsymbol{\eta}\varepsilon_{t+1} \\ \mathbf{y}_t &= \mathbf{g}_x \mathbf{x}_t \end{aligned}$$

se puede desagregar según

$$\begin{aligned} \begin{bmatrix} \mathbf{x}_{1t+1} \\ \mathbf{x}_{2t+1} \end{bmatrix} &= \begin{bmatrix} \mathbf{h}_{1x} & \mathbf{h}_{2x} \\ \mathbf{0} & \boldsymbol{\Lambda} \end{bmatrix} \begin{bmatrix} \mathbf{x}_{1t} \\ \mathbf{x}_{2t} \end{bmatrix} + \begin{bmatrix} \mathbf{0} \\ \tilde{\boldsymbol{\eta}} \end{bmatrix} \varepsilon_{t+1} \\ \mathbf{y}_t &= \begin{bmatrix} \mathbf{g}_{1x} & \mathbf{g}_{2x} \end{bmatrix} \begin{bmatrix} \mathbf{x}_{1t} \\ \mathbf{x}_{2t} \end{bmatrix} \end{aligned}$$

que equivale a

$$\begin{aligned} \mathbf{x}_{1t+1} &= \mathbf{h}_{1x}\mathbf{x}_{1t} + \mathbf{h}_{2x}\mathbf{x}_{2t} \\ \mathbf{x}_{2t+1} &= \boldsymbol{\Lambda}\mathbf{x}_{2t} + \tilde{\boldsymbol{\eta}}\varepsilon_{t+1} \\ \mathbf{y}_t &= \mathbf{g}_{1x}\mathbf{x}_{1t} + \mathbf{g}_{2x}\mathbf{x}_{2t} \end{aligned}$$

donde recuerde que $\mathbf{x}_{1t}$ involucra a rezagos de variables endógenas. Por lo tanto, el sistema de arriba se puede escribir como

$$\begin{aligned} \mathbf{y}_t &= \mathbf{g}_{1x}\mathbf{x}_{1t} + \mathbf{g}_{2x}\boldsymbol{\Lambda}\mathbf{x}_{2t-1} + \mathbf{g}_{2x}\tilde{\boldsymbol{\eta}}\varepsilon_t \\ \mathbf{x}_{1t+1} &= \mathbf{h}_{1x}\mathbf{x}_{1t} + \mathbf{h}_{2x}\boldsymbol{\Lambda}\mathbf{x}_{2t-1} + \mathbf{h}_{2x}\tilde{\boldsymbol{\eta}}\varepsilon_t \\ \mathbf{x}_{2t} &= \boldsymbol{\Lambda}\mathbf{x}_{2t-1} + \tilde{\boldsymbol{\eta}}\varepsilon_t \end{aligned}$$

```
## Hallamos los puntos en base
gx = modelo['solución']['gx']
g1x = gx[:,0]
g2x = gx[:,1:]
Lambda = modelo['SLER']['Lambda']
Eta = modelo['SLER']['Eta']
Etatilde = Eta[1:,:]
hx = modelo['solución']['hx']
h1x = np.reshape(hx[0,0],(1,1))
h2x = np.reshape(hx[0,1:],(1,2))

MatUp = np.c_[g1x,np.dot(g2x,Lambda),np.dot(g2x,Etatilde)]
MatMd = np.c_[h1x,np.dot(h2x,Lambda),np.dot(h2x,Etatilde)]
MatDw = np.c_[np.zeros(shape=(2,1)),Lambda,Etatilde]
Mat2show = np.r_[MatUp,MatMd,MatDw].T
mat2show = pd.DataFrame(Mat2show,
                        columns = ['y(t)','cons(t)','inv(t)','h(t)','w(t)','r(t)','k(t)','z(t)','u(t)'],
                        index = ['k(t-1)','z(t-1)','u(t-1)','ez(t)','eu(t)'])
mat2show
```

	y(t)	cons(t)	inv(t)	h(t)	w(t)	r(t)	k(t)	z(t)	u(t)
k(t-1)	0.162828	0.537093	-1.055280	-0.249510	0.412338	-0.837172	0.948618	0.00	0.00
z(t-1)	1.397370	0.395795	4.657166	0.667717	0.729653	1.397370	0.116429	0.95	0.00
u(t-1)	0.447370	-0.554205	3.707166	0.667717	-0.220347	0.447370	0.116429	0.00	0.95
ez(t)	0.147092	0.041663	0.490228	0.070286	0.076806	0.147092	0.012256	0.10	0.00
eu(t)	0.047092	-0.058337	0.390228	0.070286	-0.023194	0.047092	0.012256	0.00	0.10

Próximos pasos: Generar código con `mat2show` Ver gráficos recomendados New interactive sheet

Con la solución se pueden realizar el análisis del modelo con diversas métricas. Por ejemplo, se puede computar la función de respuesta a los impulso:

```
IRFy,IRFx = DG.genIRF(modelo,25) ## computa los choques de proudctividad y el numero t que quiero verlo
```

```
## ver el impulso respuesta
fig, axs = plt.subplots(2,2)
axs[0,0].plot(IRFy[0,:,0],'g')
axs[0,0].plot(IRFy[0,:,1],'b')
axs[0,0].axhline(0, color='k', lw=1)
axs[0,0].autoscale(enable=True, axis='both', tight=True)
```

```
axs[0,0].legend(['z', 'u'])
axs[0,0].set_title('PBI')

axs[0,1].plot(IRFy[1,:,0],'g')
axs[0,1].plot(IRFy[1,:,1],'b')
axs[0,1].axhline(0, color='k', lw=1)
axs[0,1].autoscale(enable=True, axis='both', tight=True)
axs[0,1].set_title('Consumo')

axs[1,0].plot(IRFy[4,:,0],'g')
axs[1,0].plot(IRFy[4,:,1],'b')
axs[1,0].axhline(0, color='k', lw=1)
axs[1,0].autoscale(enable=True, axis='both', tight=True)
axs[1,0].set_title('Salarios')

axs[1,1].plot(IRFy[5,:,0],'g')
axs[1,1].plot(IRFy[5,:,1],'b')
axs[1,1].axhline(0, color='k', lw=1)
axs[1,1].autoscale(enable=True, axis='both', tight=True)
axs[1,1].set_title('Tasa de interés')

plt.tight_layout()
```

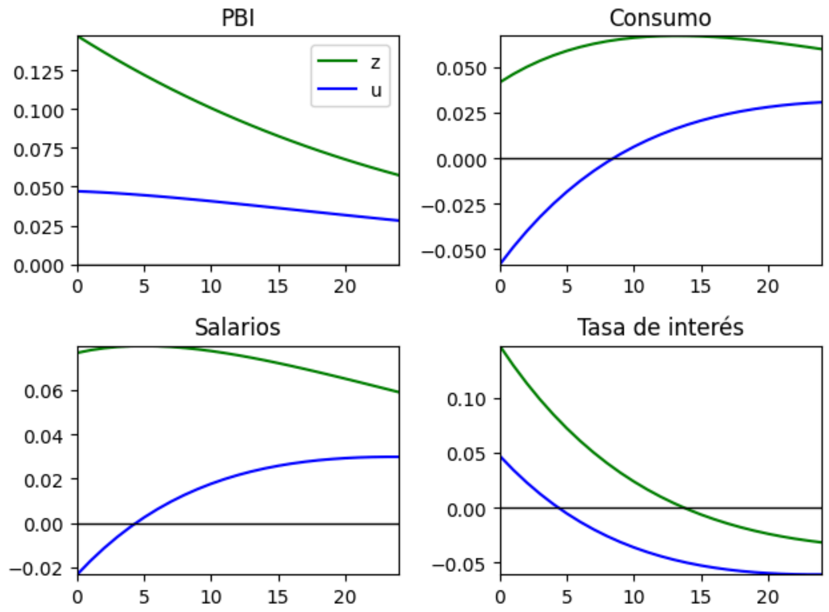

Conectando el modelo a los datos

Se estimará el modelo con los datos de PBI e inversión de USA. Estos se utilizan el logaritmos y en desvios de su tendencia [Hodrick y Prescott (1997)](#):

```
## Carga los datos
start = dt.datetime(1984,1,1)
end   = dt.datetime(2011,12,31)
RGDP = np.log(web.DataReader('GDPC1', 'fred', start=start, end=end))
RINV = np.log(web.DataReader('GPDIC1', 'fred', start=start, end=end))
Data = pd.concat([ RGDP, RINV],axis=1)
Data.columns = ['RGDP', 'RINV']
```

Comienza a programar o generar con IA.

```
Ybar,gdp = HP(Data['RGDP'].to_numpy(),1600)
Ibar,inv = HP(Data['RINV'].to_numpy(),1600) ## No es recomendable,pero se quita la tendencia porque el modelo es estacionario .La data de
# Creando un DF
df = pd.DataFrame(data=np.c_[gdp,inv])
df.to_excel('datos.xlsx') # Para reproducir en dynare
# Dibujando la data
tlab = 1984+np.array(list(range(gdp.shape[0])))/4+0.125
fig, axs = plt.subplots(1,2)
axs[0].plot(tlab,gdp,'b')
axs[0].axhline(0, color='k', lw=1)
axs[0].autoscale(enable=True, axis='both', tight=True)
axs[0].set_title('PBI')
axs[1].plot(tlab,inv,'b')
axs[1].axhline(0, color='k', lw=1)
```

```
axs[1].axhline(0, color='k', lw=1)
axs[1].autoscale(enable=True, axis='both', tight=True)
axs[1].set_title('Inversión')
plt.tight_layout()
```

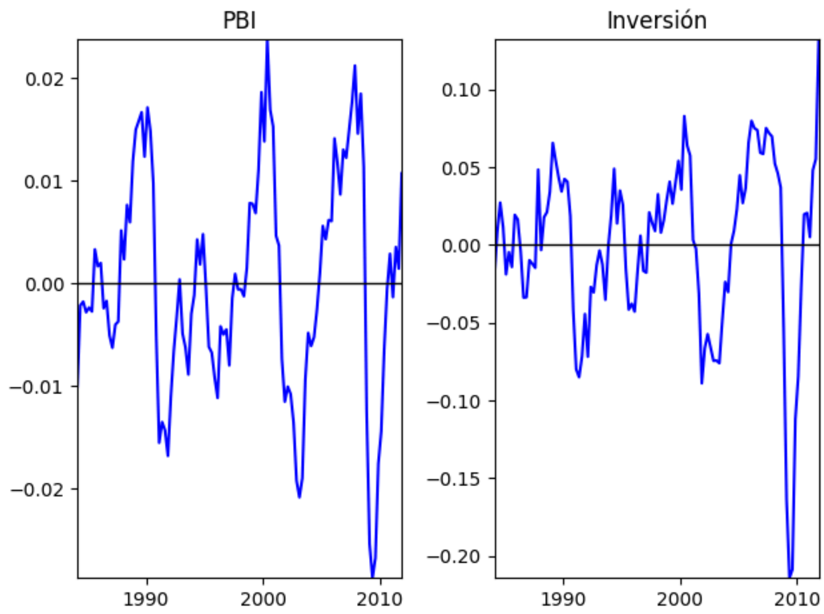

Representación de estado espacio

Según se ha mostrado, la solución del SLER tiene la forma

$$\begin{aligned} \mathbf{y}_t &= \mathbf{g}_{1x}\mathbf{x}_{1t} + \mathbf{g}_{2x}\boldsymbol{\Lambda}\mathbf{x}_{2t-1} + \mathbf{g}_{2x}\tilde{\boldsymbol{\eta}}\boldsymbol{\varepsilon}_t \\ \mathbf{x}_{1t+1} &= \mathbf{h}_{1x}\mathbf{x}_{1t} + \mathbf{h}_{2x}\boldsymbol{\Lambda}\mathbf{x}_{2t-1} + \mathbf{h}_{2x}\tilde{\boldsymbol{\eta}}\boldsymbol{\varepsilon}_t \\ \mathbf{x}_{2t} &= \boldsymbol{\Lambda}\mathbf{x}_{2t-1} + \tilde{\boldsymbol{\eta}}\boldsymbol{\varepsilon}_t \end{aligned}$$

definamos a las variables de estado de la REE como $\boldsymbol{\alpha}_t = [\mathbf{y}_t', \ \mathbf{x}_{1t+1}', \ \mathbf{x}_{2t}]'$. Noté que estos estados son de otro tipo (en contraste con los estados que se definieron al categorizar las variables del DSGE). Por lo tanto, el sistema de arriba se puede ecribir como la **ecuación de estados**:

$$\begin{bmatrix} \mathbf{y}_t \\ \mathbf{x}_{1t+1} \\ \mathbf{x}_{2t} \end{bmatrix} = \begin{bmatrix} \mathbf{0} & \mathbf{g}_{1x} & \mathbf{g}_{2x}\boldsymbol{\Lambda} \\ \mathbf{0} & \mathbf{h}_{1x} & \mathbf{h}_{2x}\boldsymbol{\Lambda} \\ \mathbf{0} & \mathbf{0} & \boldsymbol{\Lambda} \end{bmatrix} \begin{bmatrix} \mathbf{y}_{t-1} \\ \mathbf{x}_{1t} \\ \mathbf{x}_{2t-1} \end{bmatrix} + \begin{bmatrix} \mathbf{g}_{2x} \\ \mathbf{h}_{2x} \\ \mathbf{I} \end{bmatrix} \tilde{\boldsymbol{\eta}}\boldsymbol{\varepsilon}_t$$

Por su parte la **ecuación de medida** es

$$\begin{aligned} gdp_t &= y_t + v_t^y \\ inv_t &= i_t + v_t^i \end{aligned}$$

Así, las varaibles en la REE son

- $\mathbf{Y}_t = [gdp_t, \ inv_t]$
- $\boldsymbol{\alpha}_t = [\mathbf{y}_t', \ \mathbf{x}_{1t+1}', \ \mathbf{x}_{2t}'] = [y_t, \ c_t, \ i_t, \ h_t, \ w_t, \ r_t, \ k_t, \ u_t, \ z_t]'$

Recordemos que en las notas de clase, trabajamos con la siguiente notación para la REE:

$$\begin{aligned} \mathbf{Y}_t &= \mathbf{Z}\boldsymbol{\alpha}_t + \mathbf{B}\mathbf{x}_t + \boldsymbol{\varepsilon}_t \text{ con } \boldsymbol{\varepsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{H}) \\ \boldsymbol{\alpha}_t &= \mathbf{c} + \mathbf{T}\boldsymbol{\alpha}_{t-1} + \mathbf{R}\boldsymbol{\eta}_t \text{ con } \boldsymbol{\eta}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}) \end{aligned}$$

Por lo tanto,

$$\mathbf{Z} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}, \ \mathbf{B} = \mathbf{0}, \ \mathbf{H} = \begin{bmatrix} \sigma_{v,y}^2 & 0 \\ 0 & \sigma_{v,i}^2 \end{bmatrix}$$
$$\mathbf{c} = \mathbf{0}, \ \mathbf{T} = \begin{bmatrix} \mathbf{0} & \mathbf{g}_{1x} & \mathbf{g}_{2x}\boldsymbol{\Lambda} \\ \mathbf{0} & \mathbf{h}_{1x} & \mathbf{h}_{2x}\boldsymbol{\Lambda} \\ \mathbf{0} & \mathbf{0} & \boldsymbol{\Lambda} \end{bmatrix}, \ \mathbf{R} = \begin{bmatrix} \mathbf{g}_{2x} \\ \mathbf{h}_{2x} \\ \mathbf{I} \end{bmatrix} \tilde{\boldsymbol{\eta}} \text{ y } \mathbf{Q} = \mathbf{I}$$

> **Un DSGE es un VAR**: Del resumen de arriba se tiene que (ignorando $\mathbf{x}_t$ y $\boldsymbol{\varepsilon}_t$):
>
> $$\begin{aligned} \mathbf{Y}_t &= \mathbf{Z}\boldsymbol{\alpha}_t + \mathbf{B} \\ \boldsymbol{\alpha}_t &= \mathbf{c} + \mathbf{T}\boldsymbol{\alpha}_{t-1} + \mathbf{R}\boldsymbol{\eta}_t \text{ con } \boldsymbol{\eta}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}) \end{aligned}$$
>
> Note que utilizando el operador de rezagos (i.e., $LM_t = M_{t-1}$), la ecuación de transición se puede escribir de la siguiente

> manera:
> $$\boldsymbol{\alpha}_t = (\mathbf{I} - \mathbf{T})^{-1}\mathbf{c} + (\mathbf{I} - \mathbf{T}L)^{-1}\mathbf{R}\boldsymbol{\eta}_t \text{ con } \boldsymbol{\eta}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{Q})$$
> reemplazando esto en la ecuación de medida
> $$\mathbf{Y}_t = \mathbf{B} + \mathbf{Z}(\mathbf{I} - \mathbf{T})^{-1}\mathbf{c} + \mathbf{Z}(\mathbf{I} - \mathbf{T}L)^{-1}\mathbf{R}\boldsymbol{\eta}_t \text{ con } \boldsymbol{\eta}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{Q})$$
> Por lo tanto
> $$\mathbf{Y}_t = \Phi(L)\boldsymbol{\eta}_t$$
> que es la forma general de un VAR(∞).

Determinación del punto inicial: Esperanza incondicional

$$\boldsymbol{\alpha}_{0|0} = \mathrm{E}\boldsymbol{\alpha}_t : \quad \boldsymbol{\alpha}_{0|0} = (\mathbf{I} - \mathbf{T})^{-1}\mathbf{c} = \mathbf{0}$$
$$\boldsymbol{\Sigma}^{\alpha}_{0|0} = \mathrm{E}\boldsymbol{\alpha}_t\boldsymbol{\alpha}_t' : \quad \boldsymbol{\Sigma}^{\alpha}_{0|0} - \mathbf{T}\boldsymbol{\Sigma}^{\alpha}_{0|0}\mathbf{T}' - \mathbf{RQR}' = \mathbf{0}$$

la ultima ecuación es la ecuación de Lyapunov que se resuelve con la función `solve_discrete_lyapunov` del módulo `scipy`. El $\boldsymbol{\Sigma}^{\alpha}_{0|0}$ debería ser una matriz definida positiva. En caso no resulte así, se puede calcular su matriz definida positiva más cercana con la norma de Frobenius (implementada en la función `nearestSPD` del módulo `DSGEstuff.py`).

El sistema de estados está automatizado en la función `get_StatesMat` del módulo `DSGEstuff.py`. Por su parte, el sistema de medidas se especifica a continuación

```
def GenMeasureMat(solvedmodel,measureerror2): ##Define una función para devolver las que necesitamos de la ecuacion de medida
    n = solvedmodel['SLER']['dimensiones']['n'] ## solo deberiamos cambiar la medida (para lo que tenemos datos)

    Z = np.zeros(shape=(2,n))
    Z[0,0] = 1
    Z[1,2] = 1

    H = np.zeros(shape=(2,2))
    H[0,0] = measureerror2[0].item()
    H[1,1] = measureerror2[1].item()

    solvedmodel['REE']['Z']=Z
    solvedmodel['REE']['H']=H

    return solvedmodel
```

Calibramos la desviación estándar de los errores de medida como el 10% de la variación de los datos

```
MEsdgdp = np.std(gdp)*0.1
MEsdinv = np.std(inv)*0.1
```

```
modelo = DG.get_StatesMat(modelo,True)
modelo = GenMeasureMat(modelo,np.array([[MEsdgdp**2],[MEsdinv**2]]))
```

```
DG.printREE(modelo['REE']) ## devuelve las matrices
```

```
---- Matriz de transición T:
0  0  0  0  0  0  0.162828  1.39737  0.44737
0  0  0  0  0  0  0.537093  0.395795  -0.554205
0  0  0  0  0  0  -1.05528  4.65717  3.70717
0  0  0  0  0  0  -0.24951  0.667717  0.667717
0  0  0  0  0  0  0.412338  0.729653  -0.220347
0  0  0  0  0  0  -0.837172  1.39737  0.44737
0  0  0  0  0  0  0.948618  0.116429  0.116429
0  0  0  0  0  0  0  0.95  0
0  0  0  0  0  0  0  0  0.95
---- Matriz R:
0.147092  0.0470916
0.0416626  -0.0583374
0.490228  0.390228
0.070286  0.070286
0.0768056  -0.0231944
0.147092  0.0470916
0.0122557  0.0122557
0.1  0
0  0.1
---- Matriz de carga Z:
1  0  0  0  0  0  0  0  0
0  0  1  0  0  0  0  0  0
---- Matriz varianza H:
1.17918e-06  0
0  3.1432e-05
```

Utilizando el filtro de Kalman en la REE

```
data = np.c_[gdp,inv]
ops = {'compute_stderrors':False,'a_initial':modelo['REE']['alpha0'].flatten(),'P_initial':modelo['REE']['Sigma_a0']}
mod_filtered = KF.KFplus(data,modelo['REE'],ops)
```

```
modelo['REE']
```

```
{'c': array([[0.],
        [0.],
        [0.],
        [0.],
        [0.],
        [0.],
        [0.],
        [0.],
        [0.]]),
 'T': array([[ 0.        ,  0.        ,  0.        ,  0.        ,  0.        ,
          0.        ,  0.16282831,  1.39737036,  0.44737036],
        [ 0.        ,  0.        ,  0.        ,  0.        ,  0.        ,
```

```
          0.        ,  0.53709329,  0.39579493, -0.55420507],
        [ 0.        ,  0.        ,  0.        ,  0.        ,  0.        ,
          0.        , -1.05527989,  4.65716577,  3.70716577],
        [ 0.        ,  0.        ,  0.        ,  0.        ,  0.        ,
          0.        , -0.24950998,  0.66771696,  0.66771696],
        [ 0.        ,  0.        ,  0.        ,  0.        ,  0.        ,
          0.        ,  0.41233829,  0.7296534 , -0.2203466 ],
        [ 0.        ,  0.        ,  0.        ,  0.        ,  0.        ,
          0.        , -0.83717169,  1.39737036,  0.44737036],
        [ 0.        ,  0.        ,  0.        ,  0.        ,  0.        ,
          0.        ,  0.948618  ,  0.11642914,  0.11642914],
        [ 0.        ,  0.        ,  0.        ,  0.        ,  0.        ,
          0.        ,  0.        ,  0.95      ,  0.        ],
        [ 0.        ,  0.        ,  0.        ,  0.        ,  0.        ,
          0.        ,  0.        ,  0.        ,  0.95      ]]),
 'R': array([[ 0.14709162,  0.04709162],
        [ 0.04166262, -0.05833738],
        [ 0.49022798,  0.39022798],
        [ 0.070286  ,  0.070286  ],
        [ 0.07680562, -0.02319438],
        [ 0.14709162,  0.04709162],
        [ 0.0122557 ,  0.0122557 ],
        [ 0.1       ,  0.        ],
        [ 0.        ,  0.1       ]]),
 'Q': array([[1., 0.],
        [0., 1.]]),
 'alpha0': array([[0.],
        [0.],
        [0.],
        [0.],
        [0.],
        [0.],
        [0.],
        [0.],
        [0.]]),
 'Sigma_a0': array([[ 3.36771021e-01,  2.09214061e-01,  7.51926563e-01,
          8.50379733e-02,  2.51733047e-01,  5.69609566e-03,
          3.43295635e-01,  1.70540853e-01,  6.79767508e-02],
        [ 2.09214061e-01,  2.01856458e-01,  2.33160614e-01,
          4.90506851e-03,  2.04308992e-01, -8.86329788e-02,
          2.96356730e-01,  1.07638142e-01,  5.07403924e-03],
        [ 7.51926563e-01,  2.33160614e-01,  2.44033744e+00,
          3.45843966e-01,  4.06082597e-01,  3.12705906e-01,
          4.96066181e-01,  3.75268289e-01,  2.72704186e-01],
        [ 8.50379733e-02,  4.90506851e-03,  3.45843966e-01,
          5.34219365e-02,  3.16160368e-02,  6.28860497e-02,
```

```
mod_filtered['a_s'].shape
```

```
(112, 9)
```

```
a_s=mod_filtered['a_s']
a_u=mod_filtered['a_u']
a_p=mod_filtered['a_p'][1:,:]
```

Problemas con el smoothed: producto de que el modelo no es estimado

```
mat2show = pd.DataFrame(np.c_[a_p[:,0],a_u[:,0],a_s[:,0],gdp],
                        columns = ['y(t|t-1)','y(t|t)','y(t|T)','gdp(t)'],
                        index = list(range(112)))
mat2show
```

	y(t|t-1)	y(t|t)	y(t|T)	gdp(t)
0	-0.009657	-0.010024	-0.010024	-0.010024
1	-0.002024	-0.002122	-0.002124	-0.002122
2	-0.001583	-0.001748	-0.001747	-0.001749
3	-0.002632	-0.002783	-0.002781	-0.002782
4	-0.002334	-0.002327	-0.002328	-0.002324
...	...	...	...	...
107	0.002796	0.002908	0.002908	0.002909
108	-0.001269	-0.001306	-0.001308	-0.001306
109	0.003587	0.003574	0.003572	0.003572
110	0.001653	0.001471	0.001468	0.001469
111	0.010873	0.010755	0.010755	0.010751

112 rows × 4 columns

Dibujando algunos estados

```
mat2plot = a_u ## Grafica y es recomendable tener errores de medida con varianza calibrada
tlab = 1984+np.array(list(range(gdp.shape[0])))/4+0.125
fig, axs = plt.subplots(1,2)
nb = 0
axs[0].plot(tlab[nb:],gdp[nb:],'-*r')
axs[0].plot(tlab[nb:],mat2plot[nb:,0],'--g')
axs[0].axhline(0, color='k', lw=1)
axs[0].autoscale(enable=True, axis='both', tight=True)
axs[0].set_title('PBI')

axs[1].plot(tlab[nb:],inv[nb:],'-*r')
axs[1].plot(tlab[nb:],mat2plot[nb:,2],'--g')
axs[1].axhline(0, color='k', lw=1)
axs[1].autoscale(enable=True, axis='both', tight=True)
axs[1].set_title('Inversión')

plt.tight_layout()
```

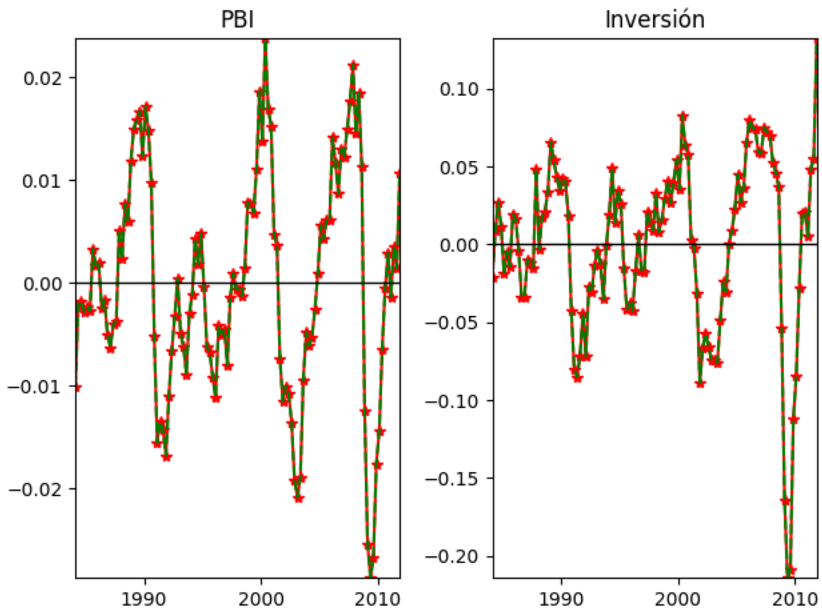


```
fig, axs = plt.subplots(4,2) ## Latente
nb = 0
axs[0,0].plot(tlab[nb:],mat2plot[nb:,7],'b')
axs[0,0].axhline(0, color='k', lw=1)
axs[0,0].autoscale(enable=True, axis='both', tight=True)
axs[0,0].set_title('z')

axs[0,1].plot(tlab[nb:],mat2plot[nb:,8],'b')
axs[0,1].axhline(0, color='k', lw=1)
axs[0,1].autoscale(enable=True, axis='both', tight=True)
axs[0,1].set_title('u')

axs[1,0].plot(tlab[nb:],mat2plot[nb:,6],'b')
axs[1,0].axhline(0, color='k', lw=1)
axs[1,0].autoscale(enable=True, axis='both', tight=True)
axs[1,0].set_title('k')

axs[1,1].plot(tlab[nb:],mat2plot[nb:,1],'b')
axs[1,1].axhline(0, color='k', lw=1)
axs[1,1].autoscale(enable=True, axis='both', tight=True)
axs[1,1].set_title('c')

axs[2,0].plot(tlab[nb:],mat2plot[nb:,3],'b')
axs[2,0].axhline(0, color='k', lw=1)
axs[2,0].autoscale(enable=True, axis='both', tight=True)
axs[2,0].set_title('h')

axs[2,1].plot(tlab[nb:],mat2plot[nb:,4],'b')
axs[2,1].axhline(0, color='k', lw=1)
axs[2,1].autoscale(enable=True, axis='both', tight=True)
axs[2,1].set_title('w')

axs[3,0].plot(tlab[nb:],mat2plot[nb:,5],'b')
axs[3,0].axhline(0, color='k', lw=1)
```

```
axs[3,0].autoscale(enable=True, axis='both', tight=True)
axs[3,0].set_title('r')


plt.tight_layout()
```

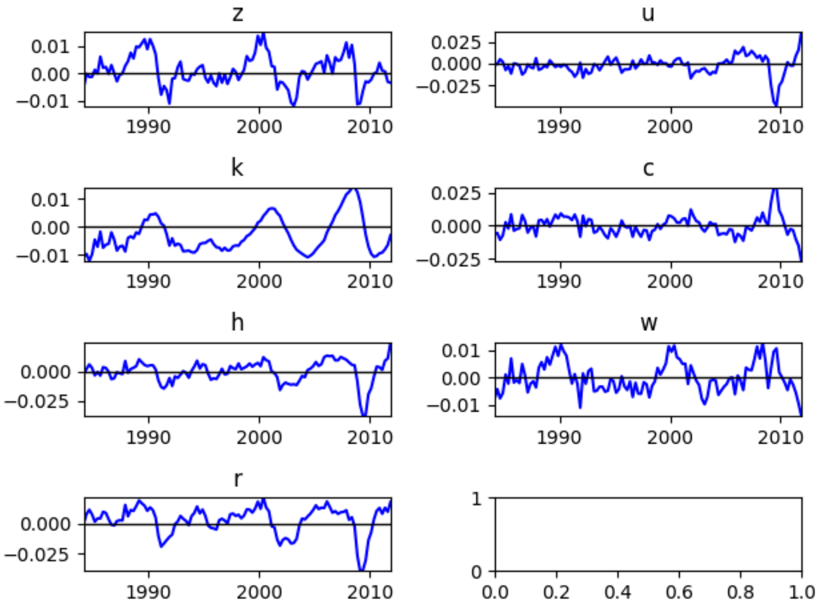


```
mod_filtered['minuslogL']#verosilimitud
```

```
-3.1843040810544814
```

Comienza a programar o generar con IA.

Estimación

Se desa estimar α, β, δ, η, ρ_z, ρ_u, σ_z, σ_u.

$$\beta = \frac{1}{1 + \frac{tasa\_imp}{100}}$$

Considere el prior: $\alpha \sim \beta(0.33, 0.05)$, $100(\beta^{-1} - 1) \sim \gamma^{-1}(1, 0.10)$, $\delta \sim \beta(0.03, 0.01)$, $\eta \sim \gamma^{-1}(0.50, 0.50)$, $\rho_z \sim \beta(0.60, 0.20)$, $\rho_u \sim \beta(0.60, 0.20)$, $100\sigma_z \sim \gamma^{-1}(2, 2)$, $100\sigma_u \sim \gamma^{-1}(2, 2)$

La función que computa el prior es:

```
PRIORmean = np.array([0.33,  #ALPHA
                      1.00,  #tBETA
                      0.03,  #DELTA
                      0.50,  #ETA
                      0.60,  #RHOz
                      0.60,  #RHOu
                      2.00,  #tSIGMAz
                      2.00]) #tSIGMAu
PRIORvar = np.array([0.20,  #ALPHA
                     1.00,  #tBETA
                     0.015, #DELTA
                     0.50,  #ETA
                     0.20,  #RHOz
                     0.20,  #RHOu
                     2.00,  #tSIGMAz
                     2.00]) #tSIGMAu
def get_minuslogprior(theta):
    from math import log
    # unpack theta
    ALPHA    = theta[0]
    tBETA    = theta[1]
    DELTA    = theta[2]
    ETA      = theta[3]
    RHOz     = theta[4]
    RHOu     = theta[5]
    SIGMAz100  = theta[6]
    SIGMAu100  = theta[7]
    # compute pdf
```

```
    pALPHA = DG.BetaPDF(ALPHA,PRIORmean[0],PRIORvar[0])
    ptBETA = DG.InvGammaPDF(tBETA,PRIORmean[1],PRIORvar[1])
    pDELTA = DG.BetaPDF(DELTA,PRIORmean[2],PRIORvar[2])
    pETA = DG.InvGammaPDF(ETA,PRIORmean[3],PRIORvar[3])
    pRHOz = DG.BetaPDF(RHOz,PRIORmean[4],PRIORvar[4])
    pRHOu = DG.BetaPDF(RHOu,PRIORmean[5],PRIORvar[5])
    pSIGMAz100 = DG.InvGammaPDF(SIGMAz100,PRIORmean[6],PRIORvar[6])
    pSIGMAu100 = DG.InvGammaPDF(SIGMAu100,PRIORmean[7],PRIORvar[7])
    ## Evaluar los beta evaluados en  los puntos
    # Joint
    pALL = pALPHA*pETA*pRHOz*pRHOu*pSIGMAz100*pSIGMAu100*pDELTA*ptBETA
    eps = np.finfo(float).eps
    if pALL <= eps:
        pALL = np.finfo(float).eps

    return -log( pALL )

##Uso el prior
```

Verosimilitud

1. Necesitamos una función que especifique el modelo en función a los parámetros que se estimarán

```
def SLERfun(theta):
    # unpack theta
    ALPHA   = theta[0].item()
    BETA    = 1/(1+theta[1].item()/100)
    DELTA   = theta[2].item()
    ETA     = theta[3].item()
    RHOz    = theta[4].item()
    RHOu    = theta[5].item()
    SIGMAz  = theta[6].item()/100
    SIGMAu  = theta[7].item()/100
    # Parametros estimado
    # Ninguno

    # pack params
    param = np.ndarray(shape=(8,1))
    param[0] = ALPHA
    param[1] = BETA
    param[2] = DELTA
    param[3] = ETA
    param[4] = RHOz
    param[5] = RHOu
    param[6] = SIGMAz
    param[7] = SIGMAu
    return RBCveranoBCRP(param) #te devuelve las mtrices que caracterizan el estado espacio
```

2. Se necesita también una función que especifique el sistema de medidas en función a los coeficientes a estimar y al SLER

```
def Measurefun(modelo): return GenMeasureMat(modelo,np.array([[MEsdgdp**2],[MEsdinv**2]])) #Modelo matriz Dsge. El getmeasure crea las r
```

3. Punto inicial: calibración

```
theta_0=np.ndarray(shape=(8,1))
theta_0[0] = ALPHA_0
theta_0[1] = 100*(1/BETA_0-1)
theta_0[2] = DELTA_0
theta_0[3] = ETA_0
theta_0[4] = RHOz_0
theta_0[5] = RHOu_0
theta_0[6] = SIGMAz_0*100
theta_0[7] = SIGMAu_0*100
theta_0

#generamos la matriz de medida
```

```
array([[ 0.33      ],
       [ 1.01010101],
       [ 0.025     ],
       [ 0.5       ],
       [ 0.95      ],
       [ 0.95      ],
```

```
          [10.        ],
          [10.        ]])
```

```
x0 = theta_0
xup = x0*1.05
xdw = x0*0.95
def minusllk(theta,data): return DG.get_minusloglike(theta,data,SLERfun,Measurefun)
def minuslps(theta,data): return DG.get_minuslogpost(theta,data,SLERfun,Measurefun,get_minuslogprior)
others = {'fcn1':minuslps}
KF.modecheck(minusllk, x0, xup, xdw, data, others)
```

```
<ipython-input-136-38af6d548a8c>:44: DeprecationWarning: Conversion of an array with ndim > 0 to a scalar is deprecated, and will er
  return -log( pALL )
```

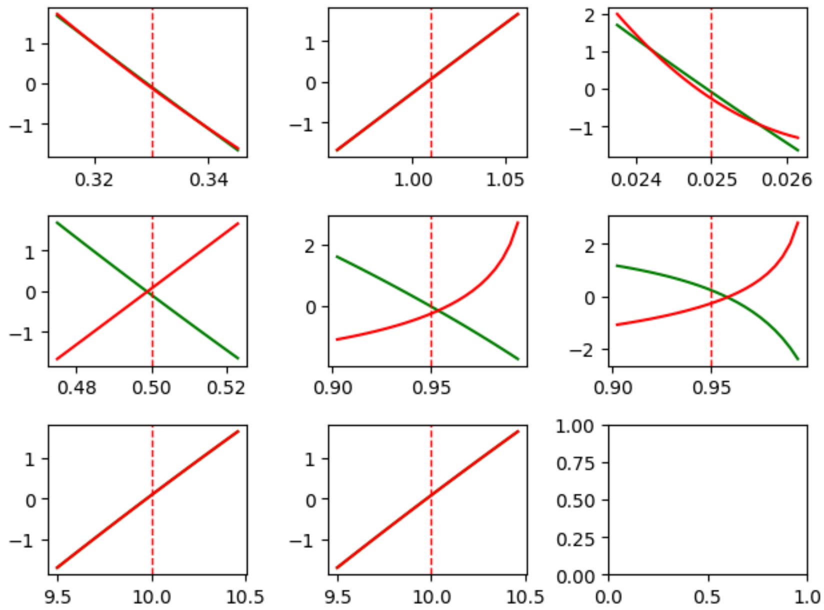


```
MinPos = 1e-6
bnds = ((MinPos, 1-MinPos),      # ALPHA
        (MinPos, None),          # BETA
        (MinPos, 1-MinPos),      # DELTA
        (MinPos,None),           # ETA
        (MinPos,1-MinPos),       # RHOz
        (MinPos,1-MinPos),       # RHOu
        (MinPos,None),           # SIGMAz
        (MinPos,None))           # SIGMAu
res = minimize(DG.get_minuslogpost, theta_0.flatten(), args=(data,SLERfun,Measurefun,get_minuslogprior), method='L-BFGS-B', options={'d:

#restricciones a los parametros
```

```
res.success
```

```
True
```

Resultados del cáculo de la moda

```
row_coefs = np.array(['ALPHA','100(1/BETA-1)','DELTA','ETA','RHOz','RHOu','100xSIGMAz','100xSIGMAu'])
col_names = np.array(['x0','xopt: moda','sd(xopt)'])
starting = theta_0
postmode = res.x
hess_inv = res.hess_inv.todense()
postmodesd = np.diag(np.linalg.cholesky(hess_inv))

mat2show = pd.DataFrame(starting, columns = [col_names[0]], index = row_coefs)
mat2show[col_names[1]]=postmode
mat2show[col_names[2]]=postmodesd

mat2show

## ver moda
```

	x0	xopt: moda	sd(xopt)
ALPHA	0.330000	0.339761	1.204253
100(1/BETA-1)	1.010101	0.499821	1.029729
DELTA	0.025000	0.023305	0.015210
ETA	0.500000	0.263298	0.263004
RHOz	0.950000	0.669975	0.637406
RHOu	0.950000	0.680390	0.517811
100xSIGMAz	10.000000	0.841905	0.440720
100xSIGMAu	10.000000	0.927648	0.490856

Verificando la convergencia

```
x0 = res.x
hess_inv = res.hess_inv.todense()
scale = 0.1
sds = np.diag(np.linalg.cholesky(hess_inv))
xup = x0+scale*sds
xdw = x0-scale*sds
KF.modecheck(minusllk, x0, xup, xdw, data, others)
```

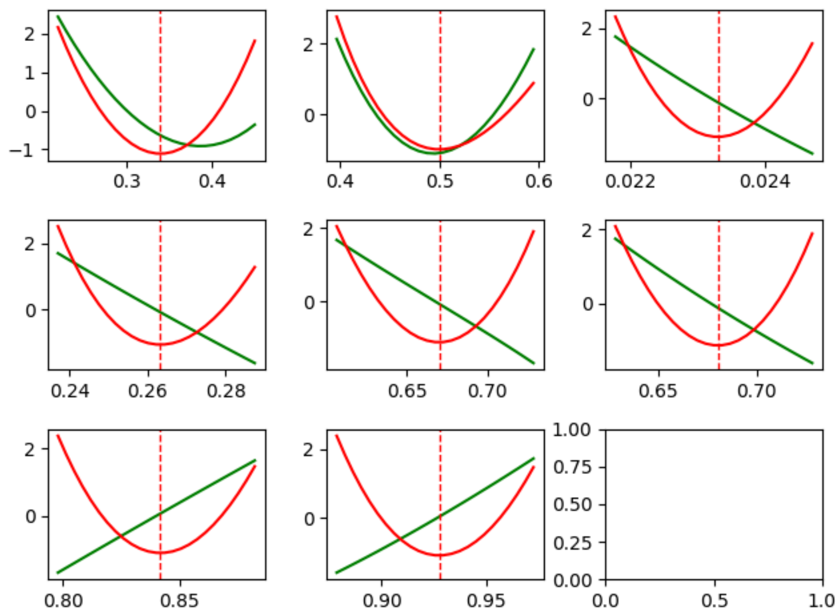

Filtrando el modelo en la moda

```
modelohat = dict()
modelohat['SLER'] = SLERfun(res.x) # Nos devuelve los matricez
modelohat = DG.SolveDSGE(modelohat)
modelohat = DG.get_StatesMat(modelohat,True)
modelohat = GenMeasureMat(modelohat,np.array([[0.001**2],[0.006**2]])*0)
ops = {'compute_stderrors':False,'a_initial':modelohat['REE']['alpha0'].flatten(),'P_initial':modelohat['REE']['Sigma_a0']}
mod_filthat = KF.KFplus(data,modelohat['REE'],ops)
#Esto estimo el DSGE en el punto de mmoda
```

```
a_u=mod_filthat['a_u']
```

```
tlab = 1984+np.array(list(range(gdp.shape[0])))/4+0.125
fig, axs = plt.subplots(4,2,figsize=(12,12))
nb = 0
axs[0,0].plot(tlab[nb:],a_u[nb:,7],'b')
axs[0,0].axhline(0, color='k', lw=1)
axs[0,0].autoscale(enable=True, axis='both', tight=True)
axs[0,0].set_title('z')

axs[0,1].plot(tlab[nb:],a_u[nb:,8],'b')
axs[0,1].axhline(0, color='k', lw=1)
axs[0,1].autoscale(enable=True, axis='both', tight=True)
axs[0,1].set_title('u')
```

```
axs[1,0].plot(tlab[nb:],a_u[nb:,6],'b')
axs[1,0].axhline(0, color='k', lw=1)
axs[1,0].autoscale(enable=True, axis='both', tight=True)
axs[1,0].set_title('k')

axs[1,1].plot(tlab[nb:],a_u[nb:,1],'b')
axs[1,1].axhline(0, color='k', lw=1)
axs[1,1].autoscale(enable=True, axis='both', tight=True)
axs[1,1].set_title('c')

axs[2,0].plot(tlab[nb:],a_u[nb:,3],'b')
axs[2,0].axhline(0, color='k', lw=1)
axs[2,0].autoscale(enable=True, axis='both', tight=True)
axs[2,0].set_title('h')

axs[2,1].plot(tlab[nb:],a_u[nb:,4],'b')
axs[2,1].axhline(0, color='k', lw=1)
axs[2,1].autoscale(enable=True, axis='both', tight=True)
axs[2,1].set_title('w')

axs[3,0].plot(tlab[nb:],a_u[nb:,5],'b')
axs[3,0].axhline(0, color='k', lw=1)
axs[3,0].autoscale(enable=True, axis='both', tight=True)
axs[3,0].set_title('r')



plt.tight_layout()
```

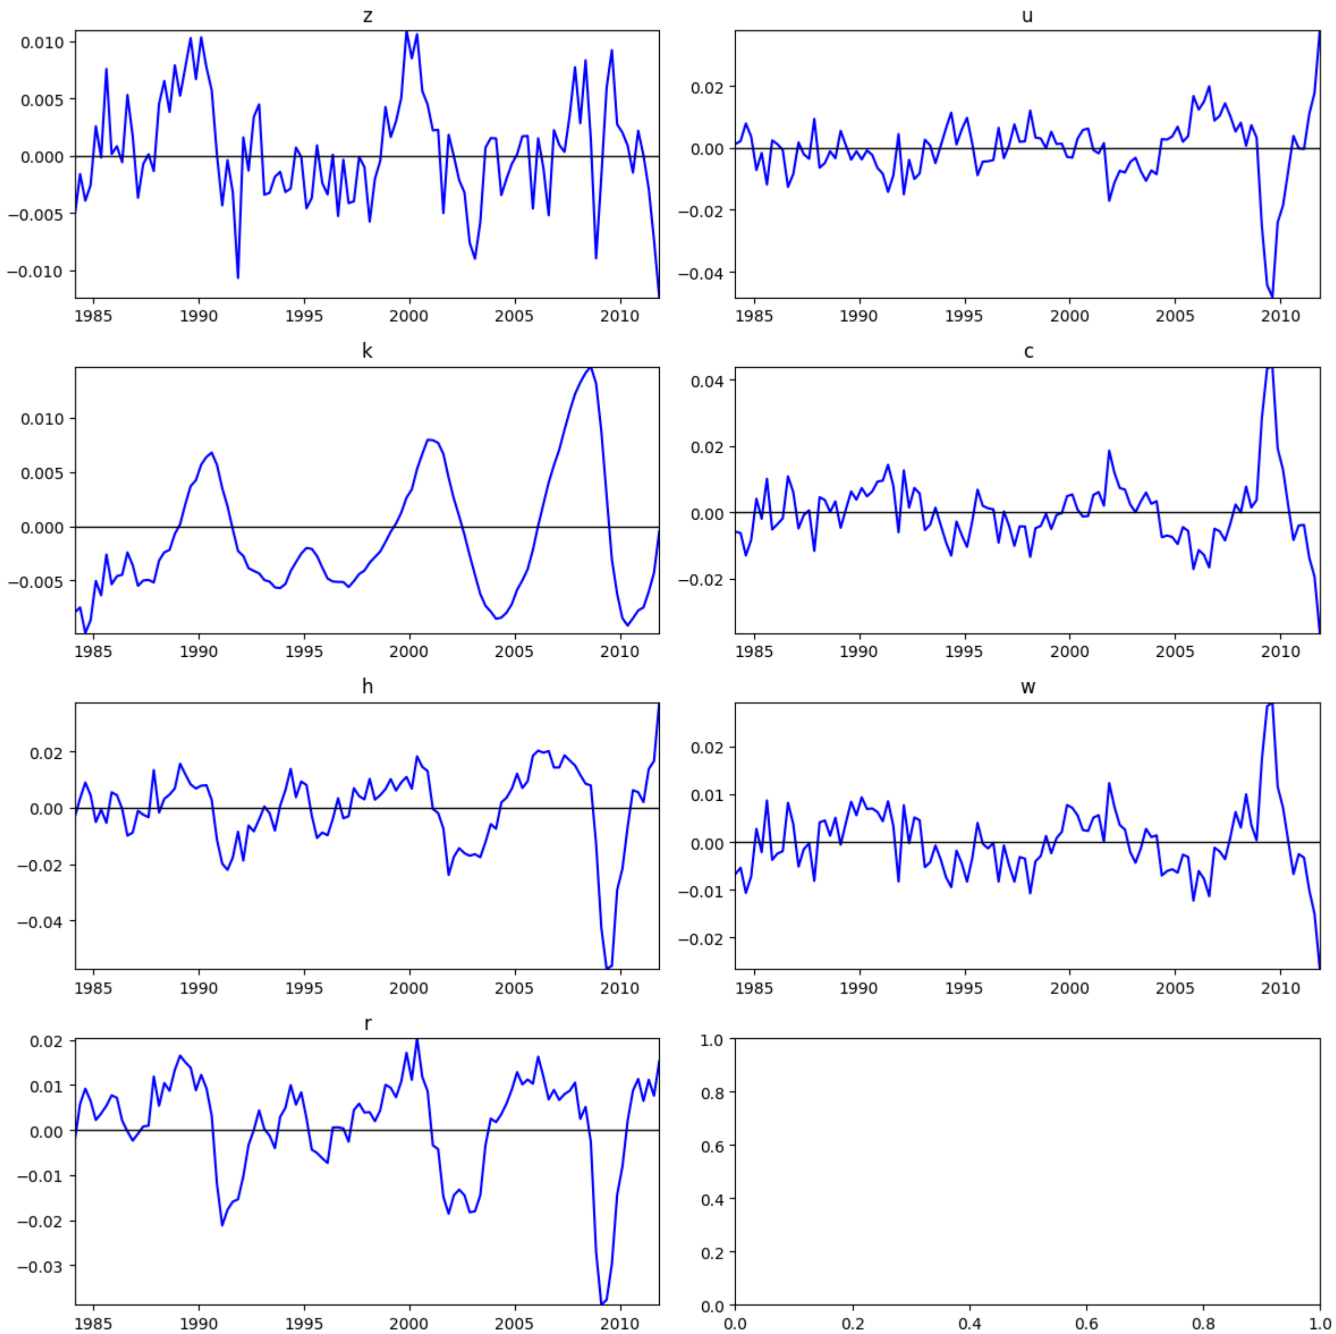

Metropolis-Hasting

```
b=100
n=10000
x0 = res.x
LTOmega = np.linalg.cholesky(hess_inv)
scale = 0.15
xsim, a, smooth_sim, updated_sim, predicted_sim = DG.get_MHdraws(n, b, SLERfun,Measurefun,get_minuslogprior, x0, LTOmega, scale, data) #
```

```
                                                    ]
-------------------------------------------------]
```

```
data.shape
```

```
(112, 2)
```

```
smooth_sim.shape
```

```
(112, 9, 10000)
```

```
xsim.shape
```

```
(8, 10000)
```

Resumen de estimación

```
row_coefs = np.array(['ALPHA','100(1/BETA-1)','DELTA','ETA','RHOz','RHOu','100xSIGMAz','100xSIGMAu'])
col_names = np.array(['PRIOR: shape','PRIOR: mean','PRIOR: var','POST: mode','POST: mean','POST: q5','POST: q95','ratio var'])
priorshape = np.array(['beta','gamma inv','beta','gamma inv','beta','beta','gamma inv','gamma inv'])
priormeansd = np.c_[PRIORmean,PRIORvar]
postmode = res.x
postmean = np.mean(xsim, axis=-1)
postq5 = np.percentile(xsim, 5, axis=-1)
postq95 = np.percentile(xsim, 95, axis=-1)
ratiovarianza = 100*np.var(xsim, axis=-1)/priormeansd[:,1]


mat2show = pd.DataFrame(priorshape, columns = [col_names[0]], index = row_coefs)
mat2show[col_names[1]]=priormeansd[:,0]
mat2show[col_names[2]]=priormeansd[:,1]
mat2show[col_names[3]]=postmode
mat2show[col_names[4]]=postmean
mat2show[col_names[5]]=postq5
mat2show[col_names[6]]=postq95
mat2show[col_names[7]]=ratiovarianza

mat2show
```

	PRIOR: shape	PRIOR: mean	PRIOR: var	POST: mode	POST: mean	POST: q5	POST: q95	ratio var
ALPHA	beta	0.33	0.200	0.339761	0.401765	0.123934	0.714939	16.511037
100(1/BETA-1)	gamma inv	1.00	1.000	0.499821	0.661995	0.301620	1.263470	9.248135
DELTA	beta	0.03	0.015	0.023305	0.034013	0.011795	0.061098	1.476683
ETA	gamma inv	0.50	0.500	0.263298	0.438271	0.145048	0.920393	11.796998
RHOz	beta	0.60	0.200	0.669975	0.571098	0.232844	0.876961	19.335581
RHOu	beta	0.60	0.200	0.680390	0.630586	0.288897	0.892490	16.948592
100xSIGMAz	gamma inv	2.00	2.000	0.841905	1.186862	0.552884	2.266254	12.901626
100xSIGMAu	gamma inv	2.00	2.000	0.927648	1.620290	0.713585	3.206092	27.635500

```
from math import floor
fig, axs = plt.subplots(8,2,figsize=(12,12))
for v in range(8):
    axs[v,0].plot(xsim[v,:],'b')
    axs[v,0].set_title('Simulación:'+row_coefs[v])
    axs[v,0].autoscale(enable=True, axis='both', tight=True)
    axs[v,1].hist(xsim[v,:],60)
    axs[v,1].set_title('Histograma:'+row_coefs[v])
    axs[v,1].autoscale(enable=True, axis='both', tight=True)

fig.tight_layout()
```

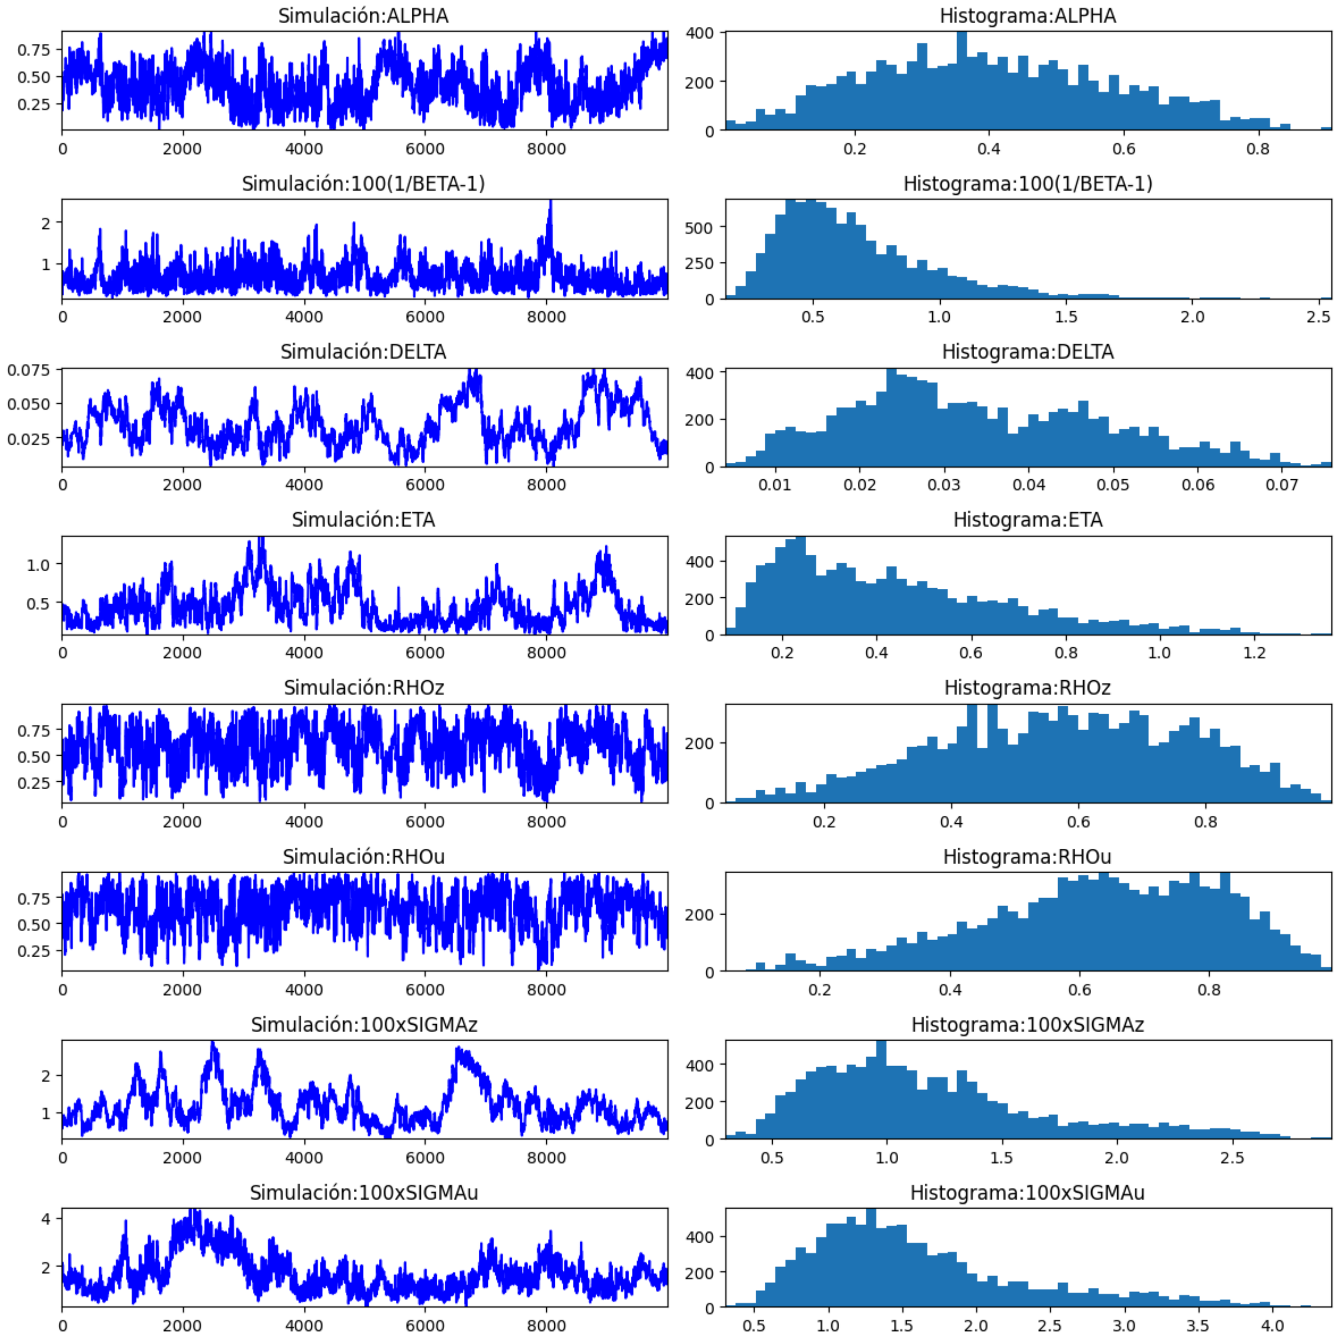


```
num_bins=60
fig, axs = plt.subplots(4,2,figsize=(12,12))
for v in range(8):
    n, bins, patches = axs[floor(v/2),v%2].hist(xsim[v,:], num_bins, density=1,label='Post')
    mu = priormeansd[v,0]
    sd = priormeansd[v,1]
    if v==0 or v==2 or v==4 or v==5:
        pdf = np.array([DG.BetaPDF(x,mu,sd) for x in bins])
    else:
        pdf = np.array([DG.InvGammaPDF(x,mu,sd) for x in bins])

    axs[floor(v/2),v%2].plot(bins, pdf,'r',label='Prior')
    axs[floor(v/2),v%2].set_title(row_coefs[v])
    axs[floor(v/2),v%2].autoscale(enable=True, axis='both', tight=True)
    axs[floor(v/2),v%2].legend()

fig.tight_layout()
```

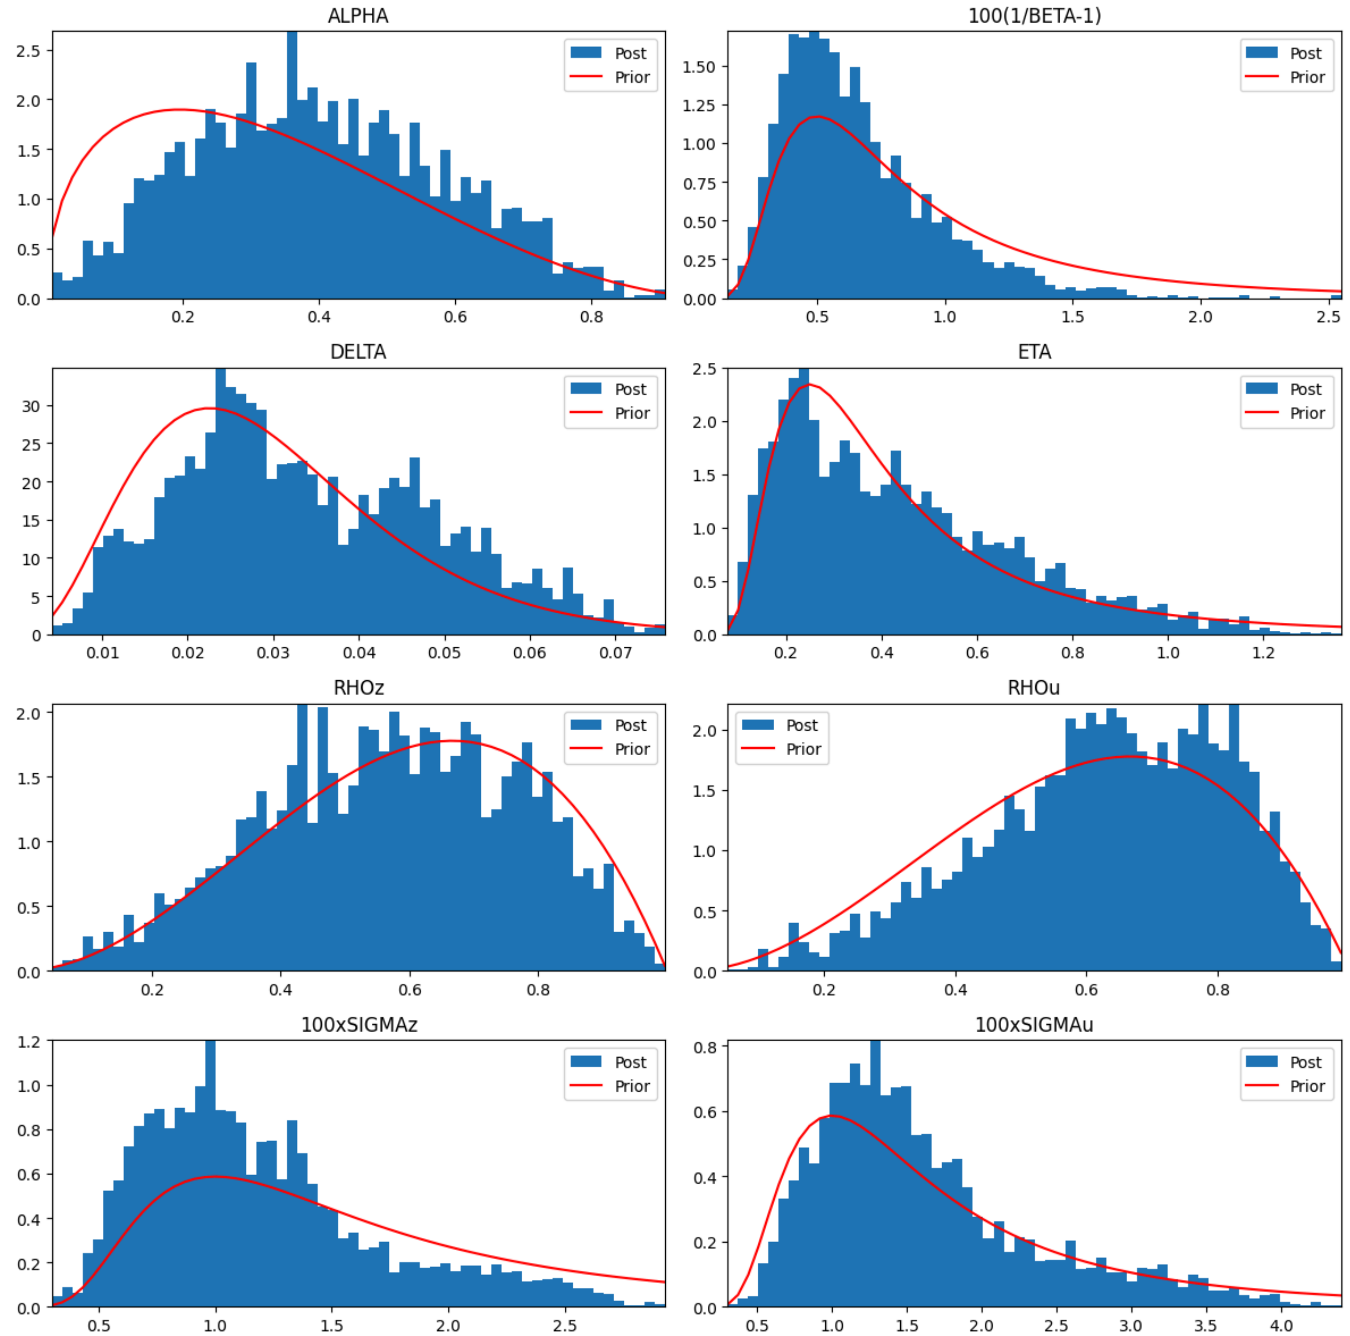

Los estados resultantes se muestran a continuación

```
obj2show = updated_sim
obj_mean = np.mean(obj2show, axis=-1)
obj_Q5 = np.percentile(obj2show, 5, axis=-1)
obj_Q95 = np.percentile(obj2show, 95, axis=-1)


tlab = 1984+np.array(list(range(gdp.shape[0])))/4+0.125
fig, axs = plt.subplots(4,2,figsize=(15,15))
nb = 0
axs[0,0].plot(tlab[nb:],obj_mean[nb:,7],'b')
axs[0,0].plot(tlab[nb:],obj_Q5[nb:,7],'--r')
axs[0,0].plot(tlab[nb:],obj_Q95[nb:,7],'--r')
axs[0,0].axhline(0, color='k', lw=1)
axs[0,0].autoscale(enable=True, axis='both', tight=True)
axs[0,0].set_title('z')

axs[0,1].plot(tlab[nb:],obj_mean[nb:,8],'b')
axs[0,1].plot(tlab[nb:],obj_Q5[nb:,8],'--r')
axs[0,1].plot(tlab[nb:],obj_Q95[nb:,8],'--r')
axs[0,1].axhline(0, color='k', lw=1)
axs[0,1].autoscale(enable=True, axis='both', tight=True)
axs[0,1].set_title('u')

axs[1,0].plot(tlab[nb:],obj_mean[nb:,6],'b')
axs[1,0].plot(tlab[nb:],obj_Q5[nb:,6],'--r')
axs[1,0].plot(tlab[nb:],obj_Q95[nb:,6],'--r')
```

```
axs[1,0].axhline(0, color='k', lw=1)
axs[1,0].autoscale(enable=True, axis='both', tight=True)
axs[1,0].set_title('k')

axs[1,1].plot(tlab[nb:],obj_mean[nb:,1],'b')
axs[1,1].plot(tlab[nb:],obj_Q5[nb:,1],'--r')
axs[1,1].plot(tlab[nb:],obj_Q95[nb:,1],'--r')
axs[1,1].axhline(0, color='k', lw=1)
axs[1,1].autoscale(enable=True, axis='both', tight=True)
axs[1,1].set_title('c')

axs[2,0].plot(tlab[nb:],obj_mean[nb:,3],'b')
axs[2,0].plot(tlab[nb:],obj_Q5[nb:,3],'--r')
axs[2,0].plot(tlab[nb:],obj_Q95[nb:,3],'--r')
axs[2,0].axhline(0, color='k', lw=1)
axs[2,0].autoscale(enable=True, axis='both', tight=True)
axs[2,0].set_title('h')

axs[2,1].plot(tlab[nb:],obj_mean[nb:,4],'b')
axs[2,1].plot(tlab[nb:],obj_Q5[nb:,4],'--r')
axs[2,1].plot(tlab[nb:],obj_Q95[nb:,4],'--r')
axs[2,1].axhline(0, color='k', lw=1)
axs[2,1].autoscale(enable=True, axis='both', tight=True)
axs[2,1].set_title('w')

axs[3,0].plot(tlab[nb:],obj_mean[nb:,5],'b')
axs[3,0].plot(tlab[nb:],obj_Q5[nb:,5],'--r')
axs[3,0].plot(tlab[nb:],obj_Q95[nb:,5],'--r')
axs[3,0].axhline(0, color='k', lw=1)
axs[3,0].autoscale(enable=True, axis='both', tight=True)
axs[3,0].set_title('r')

plt.tight_layout()
```

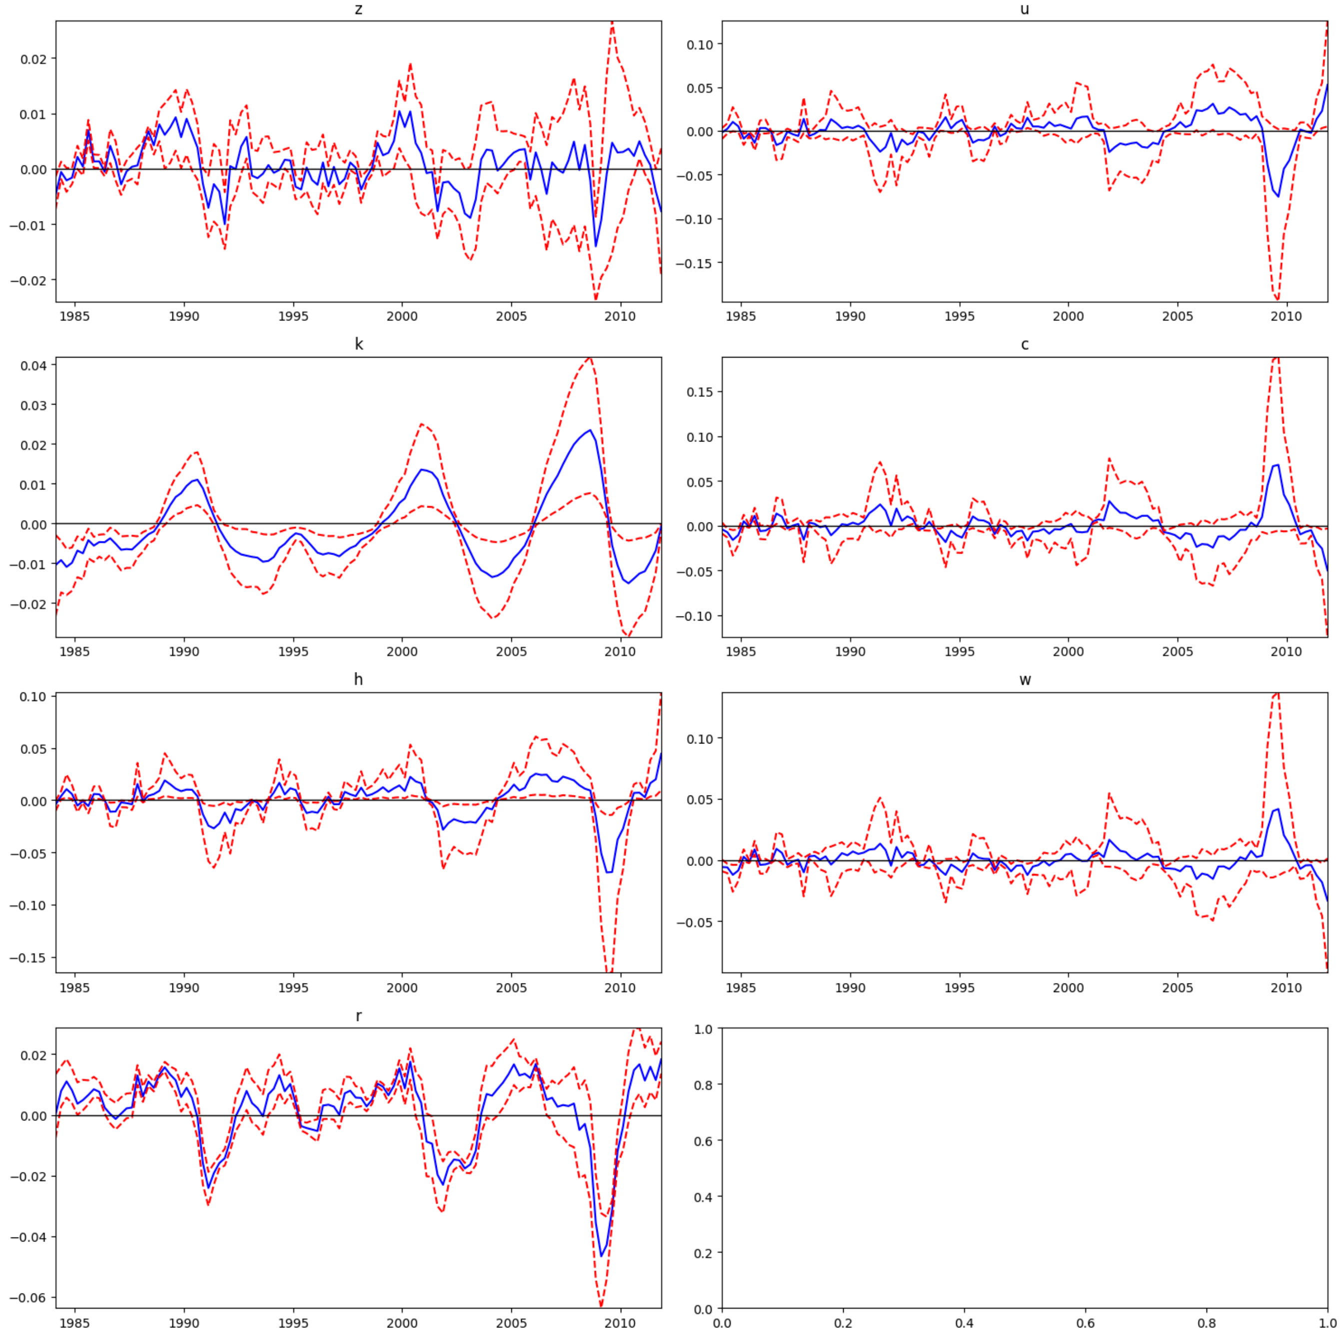

Comparar modelos

- En este modelo, se incluyeron dos choques (productividad y eficiencia de la inversión). Podría haber otro choque relevante (por ejemplo, choque de preferencias)
- La estructura fundamental del modelo podría ser diferente
- Lo ideal sería contar con varios modelos estimados, y comparar sus cualidades

Probabilidad posterior entre modelos

La probabilidad posterior de un conjunto de modelos se calcula con promedios bayesianos

$$\pi_i = \frac{\pi_{i,0} p(y|M_i)}{\sum_{j=1}^{m} \pi_{j,0} p(y|M_j)}$$

donde

- $\pi_{i,0}$ es la probabilidad prior del modelo M_i
- $p(y|M_i)$ es la verosimilitud marginal de los datos de acuerdo al modelo M_i, que se calcula de la siguiente manera

$$p(y|M_i) = \int p(y|\theta, M_i) p(\theta|M_i) \mathrm{d}\theta$$

Así, para comparae dos modelos (sea, M_1 y M_2), se puede computar los posterior odds ratios

$$\frac{\pi_1}{\pi_2} = \frac{\pi_{1,0}}{\pi_{2,0}} \frac{p(y|M_1)}{p(y|M_2)}$$

donde

- $\frac{\pi_{1,0}}{\pi_{2,0}}$ es el prior odd ratio y
- $\frac{p(y|M_1)}{p(y|M_2)}$ es el factor de bayes

Se tienen dos técnicas frecuentemente utilizadas para calcular el factor de bayes

- El estimador de medias armónicas modificadas de Geweke (1999)
- El estimador derivado de la rutina de Metropolis-Hasting de Chib y Jeliazkov (2001)

```
postmean_array = mat2show["POST: mean"].values
```

```
Comienza a programar o generar con IA.
```

```
modelo = dict()
modelo['SLER'] = RBCveranoBCRP(postmean_array)
```

```
modelo = DG.SolveDSGE(modelo)
```

```
IRFy,IRFx = DG.genIRF(modelo,25)
```

```
fig, axs = plt.subplots(2,2)
axs[0,0].plot(IRFy[0,:,0],'g')
axs[0,0].plot(IRFy[0,:,1],'b')
axs[0,0].axhline(0, color='k', lw=1)
axs[0,0].autoscale(enable=True, axis='both', tight=True)
axs[0,0].legend(['z', 'u'])
axs[0,0].set_title('PBI')

axs[0,1].plot(IRFy[1,:,0],'g')
axs[0,1].plot(IRFy[1,:,1],'b')
axs[0,1].axhline(0, color='k', lw=1)
axs[0,1].autoscale(enable=True, axis='both', tight=True)
axs[0,1].set_title('Consumo')

axs[1,0].plot(IRFy[4,:,0],'g')
axs[1,0].plot(IRFy[4,:,1],'b')
axs[1,0].axhline(0, color='k', lw=1)
axs[1,0].autoscale(enable=True, axis='both', tight=True)
axs[1,0].set_title('Salarios')

axs[1,1].plot(IRFy[5,:,0],'g')
axs[1,1].plot(IRFy[5,:,1],'b')
axs[1,1].axhline(0, color='k', lw=1)
axs[1,1].autoscale(enable=True, axis='both', tight=True)
axs[1,1].set_title('Tasa de interés')

plt.tight_layout()
```

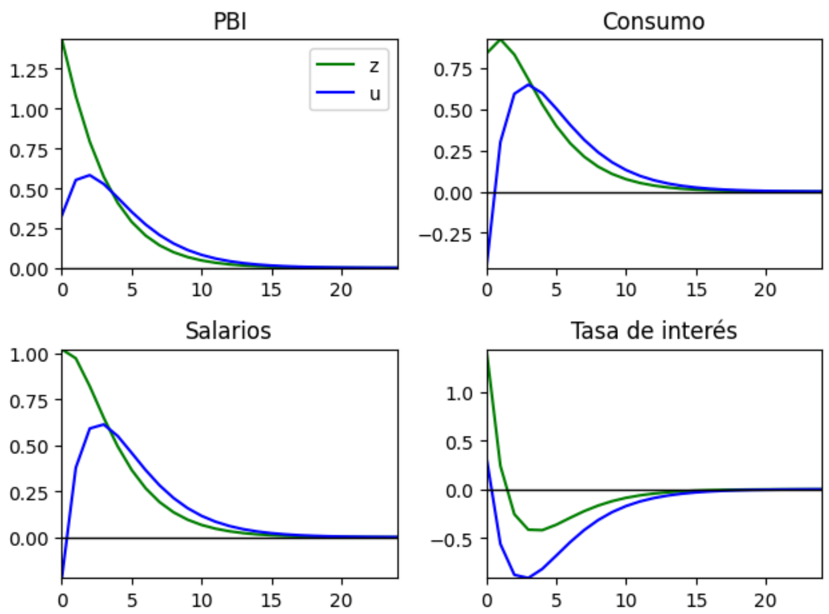


```
modelo = dict()
modelo['SLER'] = RBCveranoBCRP(param_0)
```

```
modelo = DG.SolveDSGE(modelo)
```

```
modelo = DG.get_StatesMat(modelo,True)
modelo = GenMeasureMat(modelo,np.array([[MEsdgdp**2],[MEsdinv**2]]))
```

Comienza a programar o generar con IA.

```
(8, 10000)
```

```
xsim.shape
#Objeto 8 * 10000
En este obtejo hay 8 parametros y estos tienen 10000 versiones quiero hacer lo de
 Kalman
modelo = dict()
modelo['SLER'] = RBCveranoBCRP(param_0) #inserto los 8 parametros aqui
modelo = DG.SolveDSGE(modelo)
modelo = DG.get_StatesMat(modelo,True)
modelo = GenMeasureMat(modelo,np.array([[MEsdgdp**2],[MEsdinv**2]]))
data = np.c_[gdp,inv]
ops = {'compute_stderrors':False,'a_initial':modelo['REE']['alpha0'].flatten(),'P_initial':modelo['REE']['Sigma_a0']}
mod_filtered = KF.KFplus(data,modelo['REE'],ops)
Todo lo hago 10000 veces una por cada version del conjunto de parametros dentro de ese xsimshape
#PBI
mod_filtered['a_s'][:,0] guardo solo esto de las simulaciones

me quedara una cosa gigante con 10000 versionesde lo de arriba,esas 10000 necesito sacar su mean ,y sus intervalos de confianza en base
```

```
#PBI
mod_filtered['a_s'][:,0]
```

```
(112,)
```

```
    param_i = xsim[:, 1]
```

```
import numpy as np

# Suponiendo que xsim.shape es (8, 10000)
#    -> 8 parámetros x 10000 draws
n_params = xsim.shape[0]
n_draws  = xsim.shape[1]

# Construimos un arreglo para guardar 'a_s' filtrado (columna 0)
# Asumiendo que 'data' tiene T observaciones
T = data.shape[0]
all_a_s_0 = np.zeros((T, n_draws))
```

```
for i in range(n_draws):
    # 1) Extraer el vector de parámetros de la i-ésima iteración
    param_i = xsim[:, i]

    # 2) Construir y resolver el modelo con esos parámetros
    modelo = dict()
    modelo['SLER'] = RBCveranoBCRP(param_i)      # define RBCveranoBCRP con param_i
    modelo = DG.SolveDSGE(modelo)
    modelo = DG.get_StatesMat(modelo, True)
    MEsdgdp = np.std(gdp)*0.1
    MEsdinv = np.std(inv)*0.1
    modelo = GenMeasureMat(modelo, np.array([[MEsdgdp**2],[MEsdinv**2]]))

    # 3) Correr el Filtro de Kalman
    ops = {
        'compute_stderrors': False,
        'a_initial': modelo['REE']['alpha0'].flatten(),
        'P_initial': modelo['REE']['Sigma_a0']
    }
    mod_filtered = KF.KFplus(data, modelo['REE'], ops)

    # 4) Guardar la trayectoria filtrada de la variable 'a_s'[:, 0]
    #    Suponiendo que 'mod_filtered["a_s"]' es de dimensión (T, algo)
    all_a_s_0[:, i] = mod_filtered['a_s'][:, 0]

# ----------------------------------------------------------------------
# Una vez terminadas las 10000 iteraciones, tenemos:
# all_a_s_0 con shape (T, 10000)
# ----------------------------------------------------------------------

# 5) Calcular media y percentiles (2.5 y 97.5) en cada período.
mean_a_s_0 = np.mean(all_a_s_0, axis=1)  # -> vector de dimensión (T,)
p025_a_s_0 = np.percentile(all_a_s_0, 2.5,  axis=1)
p975_a_s_0 = np.percentile(all_a_s_0, 97.5, axis=1)
```

```
El equilibrio esta localmente indeterminado
---------------------------------------------------------------------------
LinAlgError                               Traceback (most recent call last)
<ipython-input-182-dce5e3dd3c02> in <cell line: 0>()
     19     modelo['SLER'] = RBCveranoBCRP(param_i)      # define RBCveranoBCRP con param_i
     20     modelo = DG.SolveDSGE(modelo)
---> 21     modelo = DG.get_StatesMat(modelo, True)
     22     MEsdgdp = np.std(gdp)*0.1
     23     MEsdinv = np.std(inv)*0.1

                                    4 frames
/usr/local/lib/python3.11/dist-packages/numpy/linalg/linalg.py in _raise_linalgerror_singular(err, flag)
    110
    111 def _raise_linalgerror_singular(err, flag):
--> 112     raise LinAlgError("Singular matrix")
    113
    114 def _raise_linalgerror_nonposdef(err, flag):

LinAlgError: Singular matrix
```

```
import numpy as np

# Suponiendo que xsim.shape es (8, 10000)
n_draws  = xsim.shape[1]

# T es el número de observaciones del vector data (para KF)
T = data.shape[0]

# Inicializamos una matriz para almacenar los resultados
all_a_s_0 = np.zeros((T, n_draws))

valid_count = 0  # Para llevar la cuenta de cuántas corridas fueron válidas

for i in range(n_draws):
    # Extraer parámetros
    param_i = xsim[:, i]

    try:
        # Definir y resolver el modelo
        modelo = {}
        modelo['SLER'] = RBCveranoBCRP(param_i)
        modelo = DG.SolveDSGE(modelo)
        modelo = DG.get_StatesMat(modelo, True)
```

```
        MEsdgdp = np.std(gdp)*0.1
        MEsdinv = np.std(inv)*0.1
        modelo = GenMeasureMat(modelo, np.array([[MEsdgdp**2],[MEsdinv**2]]))

        # Correr el Filtro de Kalman
        ops = {
            'compute_stderrors': False,
            'a_initial': modelo['REE']['alpha0'].flatten(),
            'P_initial': modelo['REE']['Sigma_a0']
        }
        mod_filtered = KF.KFplus(data, modelo['REE'], ops)

        # Guardar el resultado (ej. a_s[:, 0])
        all_a_s_0[:, i] = mod_filtered['a_s'][:, 0]

        valid_count += 1  # Contamos como corrida válida

    except np.linalg.LinAlgError:
        # Omitimos la iteración si se produce un error de singularidad
        print(f"Iteración {i}: Singular matrix; saltando.")
        # Podrías poner all_a_s_0[:, i] = np.nan, si prefieres marcarlo con NaN
        # all_a_s_0[:, i] = np.nan
        continue

print(f"Se completaron {valid_count} corridas válidas de un total de {n_draws}.")
```

```
El equilibrio esta localmente indeterminado
Iteración 995: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 996: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 1084: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 1085: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 1086: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 1087: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 1093: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 1297: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 1379: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 1795: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 2747: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 2794: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 2795: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 3057: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 3103: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 3550: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 3588: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 3589: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 3590: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 3977: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 3978: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 4162: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 4163: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 4249: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 4250: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 4295: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 6363: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 6364: Singular matrix; saltando.
El equilibrio esta localmente indeterminado
Iteración 6421: Singular matrix; saltando.
```

```
all_a_s_0.shape
```

```
(112, 10000)
```

```
import numpy as np
import matplotlib.pyplot as plt

# Suponiendo que all_a_s_0.shape = (112, 10000)
# Cada fila (0..111) representa un periodo de tiempo,
# cada columna (0..9999) es una simulación o draw.

# 1) Calcular percentiles y media por fila
p2_5  = np.percentile(all_a_s_0, 2.5,  axis=1)   # array de longitud 112
p97_5 = np.percentile(all_a_s_0, 97.5, axis=1)   # array de longitud 112
mean_values = np.mean(all_a_s_0, axis=1)         # array de longitud 112

# 2) Graficar
plt.figure(figsize=(10,6))

# Eje temporal para 112 periodos (del 0 al 111)
t = np.arange(112)

# a) Graficar la serie observada (data[:,0])
plt.plot(t, data[:,0], label='Observado (data[:,0])', color='black')
```